

# TEORIA PROBABILITĂȚILOR ȘI STATISTICĂ MATEMATICĂ

Suport de curs

Eugen Păltănea

Universitatea Transilvania din Brașov  
2018



# Cuprins

0.1	Introducere . . . . .	4
0.1.1	Date istorice . . . . .	4
0.1.2	Descrierea cursului . . . . .	4
0.1.3	Principiile de bază. Limbaj . . . . .	4
<b>1</b>	<b>Spații măsurabile. Câmpuri de probabilitate. Scheme clasice de probabilitate</b>	<b>7</b>
1.1	Introducere . . . . .	7
1.2	Corpuri . . . . .	7
1.3	Spații măsurabile . . . . .	9
1.4	Funcții măsurabile . . . . .	10
1.5	Câmpuri de probabilitate . . . . .	11
1.6	Evenimente independente, evenimente condiționate . . . . .	13
1.7	Scheme clasice de probabilitate . . . . .	14
1.8	Rezumat . . . . .	18
1.9	Test . . . . .	22
<b>2</b>	<b>Variabile aleatoare. Caracteristici numerice</b>	<b>23</b>
2.1	Introducere . . . . .	23
2.2	Variabile aleatoare . . . . .	23
2.3	Funcția de repartiție . . . . .	24
2.4	Variabile aleatoare discrete. Exemple clasice . . . . .	26
2.5	Variabile aleatoare continue. Exemple clasice . . . . .	27
2.6	Media. Medii de ordin superior . . . . .	30
2.7	Dispersia . . . . .	32
2.8	Corelația . . . . .	33
2.9	Funcția caracteristică . . . . .	34
2.10	Rezumat . . . . .	37
2.11	Test . . . . .	40
<b>3</b>	<b>Convergența șirurilor de variabile aleatoare</b>	<b>41</b>
3.1	Introducere . . . . .	41
3.2	Inegalități fundamentale în teoria probabilităților . . . . .	41
3.3	Tipuri de convergență. Relații . . . . .	42
3.4	Legile numerelor mari . . . . .	44
3.5	Teorema limită centrală . . . . .	46
3.6	Rezumat . . . . .	48
3.7	Test . . . . .	50

<b>4</b>	<b>Elemente de statistică matematică</b>	<b>51</b>
4.1	Introducere . . . . .	51
4.2	Noțiuni de bază . . . . .	51
4.3	Estimatori. Proprietăți . . . . .	52
4.4	Estimatori bayesieni . . . . .	54
4.5	Rezumat . . . . .	56
4.6	Noțiuni de statistică descriptivă . . . . .	57
4.6.1	Concepte de bază . . . . .	57
4.6.2	Tipuri de distribuții statistice empirice. Tabele statistice. Reprezentări grafice. . . . .	59
4.6.3	Indicatori statistici . . . . .	62
4.6.4	Calculul indicatorilor statistici ai distribuției variabilei $X$ (Exemplul 1). . . . .	64
4.6.5	Calculul indicatorilor statistici ai distribuției variabilei $Y$ (Exemplul 2). . . . .	64
4.6.6	Compararea a două distribuții empirice . . . . .	65
4.6.7	Corelația și coeficientul de corelație . . . . .	65
4.6.8	Metoda corelației rangurilor . . . . .	66
4.7	Test . . . . .	67

## 0.1 Introducere

### 0.1.1 Date istorice

Teoria probabilităților<sup>1</sup> și statistica matematică studiază fenomenele aleatoare, în scopul predicției șanselor de realizare a unor rezultate așteptate. Studiul se bazează pe modelare matematică și raționamente deductive.

Bazele teoriei probabilităților și statisticii (studiului matematic al "hazardului") au fost puse în secolele XVI-XVII. Astfel, Gerolamo Cardano scria în 1526 prima carte dedicată unor concepte probabiliste: *Liber de ludo aleae* ("Cartea jocurilor de noroc"), publicată în 1663. Contribuții majore la punerea bazelor teoriei probabilităților au avut matematicienii francezi Blaise Pascal și Pierre de Fermat (începutul sec. al XVII-lea). În 1657, Cristiaan Huygens publica lucrarea *De ratiociniis in ludo aleae* ("Asupra raționamentelor în jocurile de noroc"). Doctrina probabilităților se conturează în sec. al XVIII-lea prin lucrările fundamentale *Ars conjectandi*, publicată în 1713 de Jacob Bernoulli și *The Doctrine of Chances*, publicată în 1718 de Abraham de Moivre. Un secol mai târziu, Pierre Simon Laplace publică lucrarea *Théorie analytique des probabilités*, în care evidențiază legea erorilor (convergența la legea normală). Teoria modernă a probabilităților (incluzând formalizarea axiomatică) este datorată în bună măsură matematicianului rus Andrei Nikolaevici Kolmogorov, autorul cărții *Foundation of the Theory of Probability*, publicată în 1950. Printre lucrările de referință în domeniu ale secolului XX trebuie amintite *The Theory of Stochastic Processes* (D.R Cox, H.D. Miller, 1965), *An Introduction to Probability Theory* (W. Feller, 1968) și *Probability and Measure* (P. Billingsley, 1979). În ultimii 60 de ani, studiul proceselor aleatoare cunoaște o dezvoltare și diversificare teoretică exponențială, dar și un câmp foarte larg de aplicabilitate.

Școala românească de probabilități se remarcă prin numeroase contribuții originale. Bazele acestei școli se datorează în principal matematicienilor C. T. Ionescu-Tulcea, Gheorghe Mihoc, Octav Onicescu, Ion Cuculescu, Marius Iosifescu și Constantin Tudor.

### 0.1.2 Descrierea cursului

Prezentul curs reprezintă o introducere în teoria probabilităților și statisticii matematice. Sunt descrise și caracterizate concepte de bază ale domeniului: câmpuri de probabilitate, variabile aleatoare și convergența șirurilor de variabile aleatoare, eșantioane, estimatori statistici etc. Pentru studiul acestor noțiuni sunt necesare cunoștințe elementare de analiză matematică și teoria măsurii. Cunoștințele teoretice sunt exemplificate și aplicate în probleme și lucrări de laborator, menite să familiarizeze cursantul cu raționamentele specifice domeniului și cu utilizarea unor softuri informatice.

### 0.1.3 Principiile de bază. Limbaj

Teoria probabilităților analizează șansele de realizare a unor *evenimente* în urma unei *experiențe* și este fundamentată pe următoarele trei principii:

1. Fiecărui *eveniment* rezultat în urma unei *experiențe* i se atribuie un număr real din intervalul  $[0, 1]$  numit *probabilitatea evenimentului*.

---

<sup>1</sup>Etimologie: *probabilitas* (lat.) = credibilitate

2. Oricare două *evenimente contrare* au suma probabilităților egală cu 1.
3. Probabilitatea de realizare simultană a două evenimente este egală cu produsul dintre probabilitatea realizării unuia dintre evenimente și probabilitatea realizării celui alt eveniment, condiționată de realizarea primului eveniment.

În formalizarea matematică, evenimentele care pot rezulta în urma efectuării unei experiențe reprezintă submulțimi ale unei mulțimi  $\Omega$  (interpretată ca "evenimentul sigur"). Aceste evenimente au o probabilitate de apariție (șansă de realizare). Matematic, probabilitatea este o *măsură finită*, definită pe mulțimea evenimentelor. Astfel, limbajului probabilistic îi corespunde limbajul mulțimilor.

Următoarea schemă evidențiază dualitatea de limbaj (relativ la o anumită experiență):

- *evenimentul sigur* = mulțimea totală (de referință):  $\Omega$ ;
- *evenimentul imposibil* = mulțimea vidă:  $\emptyset$ ;
- *eveniment* = submulțime a mulțimii totale:  $A \subset \Omega$ ;
- *realizarea unui eveniment asigură realizarea unui alt eveniment (implicația evenimentelor)* = incluziunea mulțimilor:  $A \subset B$ ;
- *evenimentul contrar (unui eveniment)* = complementara unei submulțimi a mulțimii totale:  $A^c = \Omega \setminus A$ ;
- *evenimentul realizării a cel puțin unuia dintre două evenimente (disjuncția evenimentelor)* = reuniunea mulțimilor:  $A \cup B$ ;
- *evenimentul realizării simultane a două evenimente (conjuncția evenimentelor)* = intersecția mulțimilor:  $A \cap B$ ;

# Capitolul 1

## Spații măsurabile. Câmpuri de probabilitate. Scheme clasice de probabilitate

### 1.1 Introducere

Vom defini și caracteriza în continuare noțiunea de spațiu măsurabil (câmp de evenimente) și funcțiile măsurabile, definite între spații măsurabile. Noțiunile respective modelează matematic rezultatele posibile ale unei experiențe (evenimentele posibile) și corespondențele specifice asociate unor experiențe. Astfel, definim noțiunile: corp,  $\sigma$ -corp, borelianul unui spațiu topologic, spațiu măsurabil, funcție măsurabilă și evidențiem proprietățile lor de bază. Se introduce noțiunea de *câmp de probabilitate* și se pregătește definirea conceptului de *variabilă aleatoare*. Sunt evidențiate proprietățile probabilității, definită ca măsură finită pe spațiul evenimentelor ( $\sigma$ -corpul evenimentelor). Este discutată independența evenimentelor și noțiunea de probabilitate condiționată. Exemplele elementare de câmpuri de probabilitate discrete sunt particularizate în modelele clasice (scheme de probabilitate), adaptate studiului unor fenomene aleatoare.

### 1.2 Corpuri

Noțiune de *corp* (de mulțimi) reprezintă cadrul minimal de modelare matematică a setului evenimentelor posibile rezultate în urma unei experiențe cu rezultate aleatoare.

**Definiția 1.2.1.** Fie  $\Omega$  o mulțime nevidă. O familie nevidă  $\mathcal{C}$  de submulțimi ale lui  $\Omega$  ( $\mathcal{C} \subset \mathcal{P}(\Omega)$ ) se numește corp a lui  $\Omega$  dacă satisface proprietățile:

$$C_1. A^c \in \mathcal{C}, \forall A \in \mathcal{C};$$

$$C_2. A \cup B \in \mathcal{C}, \forall A, B \in \mathcal{C}.$$

Definiția de mai sus are o serie de consecințe imediate.

**Propoziția 1.2.1.** Fie  $\mathcal{C}$  un corp a lui  $\Omega$ . Au loc proprietățile următoare:

$$C_3. \cup_{i=1}^n A_i \in \mathcal{C}, \forall A_i \in \mathcal{C}, i = \overline{1, n}, n \geq 2;$$

$C_4$ .  $\cap_{i=1}^n A_i \in \mathcal{C}$ ,  $\forall A_i \in \mathcal{C}$ ,  $i = \overline{1, n}$ ,  $n \geq 2$ ;

$C_5$ .  $\emptyset, \Omega \in \mathcal{C}$ ;

$C_6$ .  $A \setminus B \in \mathcal{C}$ ,  $\forall A, B \in \mathcal{C}$ .

*Demonstrație.*  $C_3$  se verifică prin inducție.  $C_4$  rezultă din următoarea relație (De Morgan):  $\cap_{i=1}^n A_i = (\cup_{i=1}^n A_i^c)^c$  și proprietățile  $C_1$  și  $C_3$ . Pentru  $C_5$ , considerăm  $A \in \mathcal{C}$ ; avem  $\Omega = A \cup A^c \in \mathcal{C}$  și  $\emptyset = A \cap A^c \in \mathcal{C}$ .  $C_6$  se obține din relația:  $A \setminus B = A \cap B^c$  și  $C_4$ .  $\square$

Vom considera în continuare intersecții de corpuri ale unei mulțimi fixate.

**Propoziția 1.2.2.** *O intersecție de corpuri ale unei mulțimi date este un corp al acelei mulțimi.*

*Demonstrație.* Fie  $\{\mathcal{C}_i : i \in I\}$  o familie de corpuri ale mulțimii  $\Omega$ . Notăm  $\mathcal{C} = \cap_{i \in I} \mathcal{C}_i \subset \mathcal{P}(\Omega)$ . Evident,  $\Omega \in \mathcal{C}$  (cf.  $P_3$ ), deci  $\mathcal{C} \neq \emptyset$ . Dacă  $A \in \mathcal{C}$ , atunci  $A \in \mathcal{C}_i$ ,  $\forall i \in I$ , de unde  $A^c \in \mathcal{C}_i$ ,  $\forall i \in I$  (cf.  $C_1$ ), deci  $A^c \in \mathcal{C}$ . Similar se verifică  $A \cup B \in \mathcal{C}$ ,  $\forall A, B \in \mathcal{C}$ . Rezultă că  $\mathcal{C}$  este un corp a lui  $\Omega$ .  $\square$

Rezultatul de mai sus este util în studiul corpurilor generate de familii de părți ale mulțimii totale considerate.

**Definiția 1.2.2.** *Fie  $\Omega \neq \emptyset$  și  $\mathcal{M} \subset \mathcal{P}(\Omega)$ ,  $\mathcal{M} \neq \emptyset$ . Fie  $\mathcal{P} = \{\mathcal{C} - \text{corp a lui } \Omega \mid \mathcal{M} \subset \mathcal{C}\}$ . Atunci mulțimea*

$$\mathcal{C}(\mathcal{M}) = \bigcap_{\mathcal{C} \in \mathcal{P}} \mathcal{C}$$

*se numește corpul generat de  $\mathcal{M}$ .*

Vom observa la  $\mathcal{C}(\mathcal{M})$  este cel mai mic corp a lui  $\Omega$  care include familia de părți  $\mathcal{M}$  a lui  $\Omega$ . Ne vom referi acum la cazul corpurilor finite.

**Propoziția 1.2.3.** *Fie  $\Omega \neq \emptyset$ .*

1. *Dacă  $\mathcal{M} \subset \mathcal{P}(\Omega)$ ,  $\mathcal{M} \neq \emptyset$ , este o mulțime finită, atunci corpul  $\mathcal{C}(\mathcal{M})$  este finit.*
2. *Dacă  $\mathcal{C}$  este un corp finit a lui  $\Omega$ , atunci există o partiție finită  $\Delta = \{A_1, A_2, \dots, A_n\}$  a lui  $\Omega$  astfel ca*

$$\mathcal{C} = \{\cup_{i \in I} A_i : I \subset \{1, 2, \dots, n\}\}.$$

*Demonstrație.*

1. Fie mulțimile finite  $\mathcal{M}^c = \{A^c : A \in \mathcal{M}\}$ ,  $\mathcal{M}_1 = \mathcal{M} \cup \mathcal{M}^c$ ,  $\mathcal{M}_2 = \{\cap_{A \in H} A : H \subset \mathcal{M}_1\}$  și  $\mathcal{M}_3 = \{\cup_{A \in G} A : G \subset \mathcal{M}_2\}$ . Atunci  $\mathcal{C}(\mathcal{M}) = \mathcal{M}_3$ , deci este finit.
2. Partiția  $\Delta$  este formată din mulțimile nevide  $A \in \mathcal{C}$ , având proprietatea următoare  $B \subset A \Rightarrow B = A$  sau  $B = \emptyset$ ,  $\forall B \in \mathcal{C}$ .  $\square$



### 1.3 Spații măsurabile

Noțiunea de corp (de mulțimi), definită în paragraful anterior, va fi extinsă în cele ce urmează la cea de  $\sigma$ -corp. Aceasta va permite introducerea noțiunii de *spațiu măsurabil* (câmp de evenimente).

**Definiția 1.3.1.** Fie  $\Omega$  o mulțime nevidă. O mulțime nevidă  $\mathcal{F} \subset \mathcal{P}(\Omega)$  se numește  $\sigma$ -corp a lui  $\Omega$  dacă satisface următoarele condiții:

$$\sigma_1. A^c \in \mathcal{F}, \forall A \in \mathcal{F};$$

$$\sigma_2. \text{dacă } A_n \in \mathcal{F}, \forall n \in \mathbb{N}^* \text{ atunci } \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}.$$

Perechea  $(\Omega, \mathcal{F})$  se numește *spațiu măsurabil* sau *câmp de evenimente*.

Vom observa că orice  $\sigma$ -corp  $\mathcal{F}$  a lui  $\Omega$  este un corp a lui  $\Omega$ . Astfel, pentru  $A, B \in \mathcal{F}$  considerăm șirul  $(A_n)_{n \geq 1}$  definit prin  $A_1 = A$  și  $A_n = B, \forall n \geq 2$ . Conform  $\sigma_1$ , avem  $A \cup B = \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$ . Deducem că  $\sigma$ -corpul  $\mathcal{F}$  este corp. Ca urmare, proprietățile  $C_3 - C_6$  rămân valabile într-un  $\sigma$ -corp. Alte proprietăți sunt descrise în propoziția următoare.

**Propoziția 1.3.1.** Fie  $(\Omega, \mathcal{F})$  un spațiu măsurabil. Au loc următoarele proprietăți:

$$\sigma_3. A_n \in \mathcal{F}, \forall n \in \mathbb{N}^* \Rightarrow \bigcap_{n=1}^{\infty} A_n \in \mathcal{F};$$

$$\sigma_4. A_n \in \mathcal{F}, \forall n \in \mathbb{N}^* \Rightarrow \limsup_{n \rightarrow \infty} A_n \in \mathcal{F}, \liminf_{n \rightarrow \infty} A_n \in \mathcal{F},$$

$$\text{unde } \limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k \text{ și } \liminf_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k.$$

*Demonstrație.*  $\sigma_3$ . Conform relațiilor lui De Morgan și Definiției 1.3.1, avem:  $\bigcap_{n=1}^{\infty} A_n = (\bigcup_{n=1}^{\infty} A_n^c)^c \in \mathcal{F}$ .

$\sigma_4$ . Se aplică  $\sigma_2$  și  $P_5$ .  $\square$

Remarcăm că familiile  $\mathcal{F}_1 = \mathcal{P}(\Omega)$  și  $\mathcal{F}_2 = \{\emptyset, \Omega\}$  reprezintă  $\sigma$ -corpuri (deci și corpuri) elementare ale lui  $\Omega$ .

Intersecția unor  $\sigma$ -corpuri ale unei mulțimi este de asemenea un  $\sigma$ -corp al mulțimii respective, demonstrația fiind similară celei din Propoziția 1.2.2.

**Propoziția 1.3.2.** Dacă  $\mathcal{F}_i, i \in I$ , reprezintă o familie oarecare de  $\sigma$ -corpuri ale mulțimii  $\Omega$ , atunci  $\bigcap_{i \in I} \mathcal{F}_i$  reprezintă de asemenea un corp al mulțimii  $\Omega$ .

Proprietatea de mai sus permite definirea noțiunii de  $\sigma$ -corp generat de o mulțime de părți (submulțimi) ale unei mulțimi  $\Omega$ .

**Definiția 1.3.2.** Fie  $\Omega$  o mulțime nevidă și  $\mathcal{M} \subset \mathcal{P}(\Omega)$ . Intersecția tuturor  $\sigma$ -corpurilor lui  $\Omega$  care includ mulțimea  $\mathcal{M}$  se numește  $\sigma$ -corpul generat de  $\mathcal{M}$  și se notează  $\mathcal{B}(\mathcal{M})$ .

Mulțimea  $\mathcal{B}(\mathcal{M})$  este cel mai mic  $\sigma$ -corp a lui  $\Omega$  care include pe  $\mathcal{M}$ . Un caz particular foarte important este cel în care mulțimea  $\mathcal{M}$  este o topologie pe spațiul  $\Omega$ .

**Definiția 1.3.3.** Fie  $(\Omega, \mathcal{O})$  un spațiu topologic, unde  $\mathcal{O}$  reprezintă topologia lui  $\Omega$  (familia mulțimilor deschise). Atunci  $\sigma$  – corpul generat de mulțimea  $\mathcal{O}$  se numește borelianul spațiului topologic  $(\Omega, \mathcal{O})$  și se notează (atunci când nu este pericol de confuzie) prin  $\mathcal{B}_\Omega$ .

Topologia  $\mathcal{O}_\mathbb{R}$  a mulțimii numerelor reale  $\mathbb{R}$  este familia reuniunilor cel mult numărabile de intervale deschise disjuncte. Se poate demonstra că borelianul  $\mathcal{B}_\mathbb{R}$  al spațiului topologic  $(\mathbb{R}, \mathcal{O}_\mathbb{R})$  conține toate tipurile de intervale și reuniunile cel mult numărabile ale acestora. Reciproc,  $\mathcal{B}_\mathbb{R}$  coincide cu  $\sigma$  - corpul generat de oricare tip de intervale reale.

## 1.4 Funcții măsurabile

Descriem în continuare funcțiile ”specifice” spațiilor măsurabile.

**Definiția 1.4.1.** Fie  $(\Omega, \mathcal{F})$  și  $(\Omega', \mathcal{F}')$  o pereche de spații măsurabile (câmpuri de evenimente). O funcție  $f : \Omega \rightarrow \Omega'$  se numește funcție măsurabilă dacă

$$f^{-1}(A) \in \mathcal{F}, \quad \forall A \in \mathcal{F}',$$

unde  $f^{-1}(A) = \{\omega \in \Omega \mid f(\omega) \in A\}$ .

În particular, dacă  $\Omega' = \mathbb{R}$  și  $\mathcal{F}' = \mathcal{B}_\mathbb{R}$ , funcția  $f$  se va numi *funcție reală măsurabilă*. De remarcat faptul că, pentru o funcție reală măsurabilă  $f : \Omega \rightarrow \mathbb{R}$ , avem:

- $\{f \leq a\} := f^{-1}((-\infty, a]) \in \mathcal{F}, \quad \forall a \in \mathbb{R}$
- $\{f > a\} := f^{-1}((a, \infty)) \in \mathcal{F}, \quad \forall a \in \mathbb{R}$
- $\{a \leq f \leq b\} := f^{-1}([a, b]) \in \mathcal{F}, \quad \forall a, b \in \mathbb{R}, \quad a < b.$

Conservarea măsurabilității prin operații algebrice este stabilită de propoziția următoare.

**Propoziția 1.4.1.** Fie  $(\Omega, \mathcal{F})$  un spațiu măsurabil. Dacă  $f, g : \Omega \rightarrow \mathbb{R}$  sunt funcții reale măsurabile și  $a \in \mathbb{R}$  atunci funcțiile reale  $f+a$ ,  $af$ ,  $|f|$ ,  $f+g$ ,  $fg$ ,  $\min\{f, g\}$  și  $\max\{f, g\}$  sunt măsurabile.

Funcțiile continue sunt măsurabile. Astfel, are loc:

**Propoziția 1.4.2.** Dacă  $(\Omega, \mathcal{B}_\Omega)$  este un spațiu măsurabil, cu  $\mathcal{B}_\Omega$  reprezentând borelianul definit de o topologie pe  $\Omega$ , iar  $f : \Omega \rightarrow \mathbb{R}$  este o funcție continuă, atunci  $f$  este o funcție reală măsurabilă.

Noțiunea de *funcție reală măsurabilă* servește definirii noțiunii de *variabilă aleatoare*.

## 1.5 Câmpuri de probabilitate

Noțiunea de câmp de probabilitate este fundamentală în teoria probabilităților. Un câmp de probabilitate este un spațiu măsurabil dotat cu o măsură finită numită ”probabilitate”.

**Definiția 1.5.1.** Fie  $(\Omega, \mathcal{F})$  un spațiu măsurabil, cu  $\sigma$  – corpul  $\mathcal{F}$  denumit ”mulțimea evenimentelor”. O funcție  $\mathbb{P} : \mathcal{F} \rightarrow \mathbb{R}$  se numește probabilitate dacă satisface următoarele axiome:

P1.  $\mathbb{P}(A) \geq 0, \forall A \in \mathcal{F};$

P2.  $\mathbb{P}(\Omega) = 1;$

P3. Pentru oricare șir de evenimente  $(A_n)_{n \in \mathbb{N}^*}$ , cu  $A_n \cap A_m = \emptyset, \forall n \neq m$ , are loc relația

$$\mathbb{P}(\cup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Tripletul  $(\Omega, \mathcal{F}, \mathbb{P})$  se numește câmp de probabilitate.

Ultima proprietate a definiției de mai sus se referă la șiruri de evenimente. În continuare, ne vom referi la șirurile monotone de evenimente și limitele de șiruri de evenimente.

**Definiția 1.5.2.** Fie  $(A_n)_{n \in \mathbb{N}^*}$  un șir de evenimente din câmpul de probabilitate  $(\Omega, \mathcal{F}, \mathbb{P})$ .

1. Șirul  $(A_n)_{n \in \mathbb{N}^*}$  se numește monoton crescător dacă  $A_n \subset A_{n+1}, \forall n \geq 1$ . Fie  $A = \cup_{n=1}^{\infty} A_n \in \mathcal{F}$ . Notăm  $\lim_{n \rightarrow \infty} A_n = A$  și  $A \uparrow$ .

2. Șirul  $(A_n)_{n \in \mathbb{N}^*}$  se numește monoton descrescător dacă  $A_{n+1} \subset A_n, \forall n \geq 1$ . Fie  $A = \cap_{n=1}^{\infty} A_n \in \mathcal{F}$ . Notăm  $\lim_{n \rightarrow \infty} A_n = A$  și  $A \downarrow$ .

3. Limita superioară a șirului  $(A_n)_{n \in \mathbb{N}^*}$  se definește prin

$$\limsup_{n \rightarrow \infty} A_n = \cap_{n=1}^{\infty} \cup_{k=n}^{\infty} A_k \in \mathcal{F}.$$

4. Limita inferioară a șirului  $(A_n)_{n \in \mathbb{N}^*}$  se definește prin

$$\liminf_{n \rightarrow \infty} A_n = \cup_{n=1}^{\infty} \cap_{k=n}^{\infty} A_k \in \mathcal{F}.$$

Probabilitatea are o serie de proprietăți fundamentale care decurg din Definiția 1.5.1. Aceste proprietăți caracterizează în fapt o măsură finită.

**Propoziția 1.5.1.** Fie  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmp de probabilitate. Au loc următoarele proprietăți

P4.  $\mathbb{P}(\emptyset) = 0;$

P5.  $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B), \forall A, B \in \mathcal{F}, A \cap B = \emptyset;$

P6.  $\mathbb{P}(A^c) = 1 - \mathbb{P}(A), \forall A \in \mathcal{F};$

P7.  $\mathbb{P}(A \setminus B) = \mathbb{P}(A) - \mathbb{P}(B)$ ,  $\forall A, B \in \mathcal{F}$ ,  $B \subset A$ ;

P8.  $\mathbb{P}(A) \leq \mathbb{P}(B)$ ,  $\forall A, B \in \mathcal{F}$ ,  $A \subset B$ ;

P9.  $\mathbb{P}(A) \in [0, 1]$ ,  $\forall A \in \mathcal{F}$ ;

P10. (Formula lui Poincaré)

$$\mathbb{P}(\cup_{i=1}^n A_i) = \sum_{k=1}^n (-1)^{k+1} \sum_{1 \leq i_1 < i_2 < \dots < i_k \leq n} \mathbb{P}(\cap_{j=1}^k A_{i_j});$$

P11. Dacă  $(A_n)_{n \geq 1}$  este un şir monoton (crescător sau descrescător) de evenimente, cu  $\lim_{n \rightarrow \infty} A_n = A$ , atunci  $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \mathbb{P}(A)$ .

P12. Pentru oricare şir de evenimente  $(A_n)_{n \in \mathbb{N}^*}$  avem

$$\mathbb{P}(\cup_{n=1}^{\infty} A_n) \leq \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

*Demonstrație.*

P4. Presupunem, prin absurd, că  $\mathbb{P}(\emptyset) = p > 0$ . Considerăm şirul  $A_n = \emptyset$ ,  $n \in \mathbb{N}^*$ . Conform [P3],  $\mathbb{P}(\emptyset) = \mathbb{P}(\cup_{n=1}^{\infty} (A_n)) = \sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$ . Contradicție.

P5. Alegem şirul  $A_n = \emptyset$ ,  $n \geq 3$ ,  $A_1 = A$  și  $A_2 = B$  și aplicăm [P3], [P4].

P6. Relația rezultă din  $A^c \cup A = \Omega$  și proprietățile [P2], [P5].

P7. Se obține din  $A = B \cup (A \setminus B)$  și [P5].

P8. Rezultă din proprietatea anterioară, [P7].

P9. Consecință a proprietăților [P1], [P2] și [P8].

P10. Formula se demonstrează prin inducție matematică.

P11. Presupunem  $A_n \downarrow \emptyset$ . Avem  $A_1 = \cup_{n=1}^{\infty} (A_n \setminus A_{n+1})$ , cu  $(A_i \setminus A_{i+1}) \cap (A_j \setminus A_{j+1}) = \emptyset$ ,  $\forall i \neq j$ . Atunci  $\mathbb{P}(A_1) = \sum_{n=1}^{\infty} \mathbb{P}(A_n \setminus A_{n+1})$ . Rezultă  $\lim_{n \rightarrow \infty} \sum_{k=n}^{\infty} \mathbb{P}(A_k \setminus A_{k+1}) = 0$ . Dar  $\sum_{k=n}^{\infty} \mathbb{P}(A_k \setminus A_{k+1}) = \mathbb{P}(\cup_{n=1}^{\infty} (A_n \setminus A_{n+1})) = \mathbb{P}(A_n)$ . Deci  $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = 0 = \mathbb{P}(\emptyset)$ .

Presupunem  $A_n \downarrow A$ . Atunci  $(A_n \setminus A) \downarrow \emptyset$ , de unde  $\lim_{n \rightarrow \infty} \mathbb{P}(A_n \setminus A) = 0$  și obținem  $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \mathbb{P}(A)$ .

Presupunem  $A_n \uparrow A$ . Atunci  $A_n^c \downarrow A^c$ . Rezultă  $\lim_{n \rightarrow \infty} \mathbb{P}(A_n^c) = \mathbb{P}(A^c)$ , de unde obținem  $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \mathbb{P}(A)$ .

P12. Definim şirul de evenimente  $(B_n)_{n \geq 1}$ ,  $B_1 = A_1$ ,  $B_n = A_n \setminus (\cup_{k=1}^{n-1} A_k) \subset A_n$ ,  $\forall n > 1$ . Avem  $\cup_{k=1}^n B_k = \cup_{k=1}^n A_k$ ,  $\forall n \geq 1$  și  $B_i \cap B_j = \emptyset$ ,  $\forall i \neq j$ . Ca urmare, conform proprietăților [P3] și [P8], avem

$$\mathbb{P}(\cup_{n=1}^{\infty} A_n) = \mathbb{P}(\cup_{n=1}^{\infty} B_n) = \sum_{n=1}^{\infty} \mathbb{P}(B_n) \leq \sum_{n=1}^{\infty} \mathbb{P}(A_n),$$

ceea ce trebuia demonstrat.  $\square$

## 1.6 Evenimente independente, evenimente condiționate

Un fenomen important studiat de teoria probabilităților este cel al dependenței (respectiv independenței) evenimentelor.

**Definiția 1.6.1.** Fie  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmp de probabilitate. Considerăm un eveniment  $A \in \mathcal{F}$ , cu  $\mathbb{P}(A) > 0$ . Pentru oricare eveniment  $B \in \mathcal{F}$  numim probabilitatea lui  $B$  condiționată de (realizarea evenimentului)  $A$  mărimea:

$$\mathbb{P}(B|A) := \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)}.$$

Evenimentele  $A$  și  $B$  se numesc evenimente independente dacă  $\mathbb{P}(B|A) = \mathbb{P}(B)$ , adică  $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$ . Mai general,  $\mathcal{G} \subset \mathcal{F}$  se numește familie de evenimente independente dacă pentru oricare evenimente distincte  $A_1, A_2, \dots, A_n \in \mathcal{G}$  avem

$$\mathbb{P}(\cap_{i=1}^n A_i) = \prod_{i=1}^n \mathbb{P}(A_i).$$

Se constată astfel că două evenimente sunt independente dacă probabilitatea realizării unuia dintre acestea nu este influențată de realizarea celuilalt. Se arată cu ușurință că evenimentele contrare ale unor evenimente independente sunt de asemenea independente. Pe de altă parte, conceptul de *evenimente condiționate* permite considerarea *sistemelor complete de evenimente*.

**Definiția 1.6.2.** Evenimentele  $A_i$ ,  $i \in I$ , unde  $I$  este o mulțime cel mult numărabilă de indici, formează un sistem complet de evenimente în câmpul de probabilitate  $(\Omega, \mathcal{F}, \mathbb{P})$  dacă:

1.  $A_i \cap A_j = \emptyset$ ,  $\forall i \neq j$
2.  $\cup_{i \in I} A_i = \Omega$
3.  $\mathbb{P}(A_i) > 0$ ,  $\forall i \in I$

**Propoziția 1.6.1.** Fie  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmp de probabilitate, iar  $A_i$ ,  $i \in I$ , un sistem complet de evenimente. Dacă  $A$  este un eveniment cu probabilitate nenulă, atunci loc:

1. Formula probabilității totale

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A|A_i)\mathbb{P}(A_i)$$

2. Formula lui Bayes

$$\mathbb{P}(A_k|A) = \frac{\mathbb{P}(A|A_k)\mathbb{P}(A_k)}{\sum_{i \in I} \mathbb{P}(A|A_i)\mathbb{P}(A_i)}, \quad \forall k \in I.$$

*Demonstrație.*

1. Avem

$$A = A \cap \Omega = A \cap (\cup_{i \in I} A_i) = \cup_{i \in I} (A \cap A_i).$$

Deoarece evenimentele  $A \cap A_i$ ,  $i \in I$  sunt incompatibile două câte două, obținem

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A \cap A_i) = \sum_{i \in I} \mathbb{P}(A|A_i) \mathbb{P}(A_i),$$

deci formula probabilității totale este demonstrată.

2. Fie  $k \in I$ . Conform Definiției 1.6.1 și formulei probabilității totale, obținem

$$\mathbb{P}(A_k|A) = \frac{\mathbb{P}(A \cap A_k)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A|A_k)\mathbb{P}(A_k)}{\sum_{i \in I} \mathbb{P}(A|A_i)\mathbb{P}(A_i)},$$

deci formula lui Bayes este demonstrată.  $\square$

## 1.7 Scheme clasice de probabilitate

Prezentăm în continuare modelele de bază de câmpuri de probabilitate (discrete).

1. *Câmpul lui Laplace.*

Spațiul  $\Omega$  este considerat o mulțime finită, iar  $\sigma$ -corpul  $\mathcal{F}$  este considerat mulțimea  $\mathcal{P}(\Omega)$  (mulțimea submulțimilor lui  $\Omega$ ). Probabilitatea unui eveniment  $A \subset \Omega$  se definește prin:

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|},$$

unde  $|M|$  reprezintă numărul elementelor unei mulțimi finite  $M$ . Elementele lui  $\Omega$  determină evenimentele *elementare*, *echiprobabile*. Astfel, pentru  $\omega \in \Omega$ , avem

$$\mathbb{P}(\{\omega\}) = \frac{1}{n},$$

unde  $n = |\Omega|$ .

2. *Câmp discret de evenimente.*

Considerăm  $\Omega = \{\omega_i : i \in I\}$ , unde mulțimea de indici  $I$  este cel mult numărabilă. Definim  $\mathcal{F} = \mathcal{P}(\Omega)$ . Considerăm o măsură de probabilitate  $(p_i)_{i \in I}$  pe mulțimea  $\Omega$ , unde  $p_i \geq 0$ ,  $\forall i \in I$  și  $\sum_{i \in I} p_i = 1$ . Probabilitatea unui eveniment  $A = \{\omega_j : j \in J\}$ , cu  $J \subset I$ , se definește prin

$$\mathbb{P}(A) = \sum_{j \in J} p_j.$$

Modelele de mai sus se materializează concret în *scheme de probabilitate*. Este vorba exemple cu un grad mare de generalitate și utilizare frecventă în *calculul probabilităților*. Prezentăm în continuare cele mai cunoscute scheme de probabilitate.

### 1. Schema lui Bernoulli.

Este un exemplu de câmp Laplace. Schema modelează următoarea experiență:

O urnă conține  $c$  bile, dintre care  $a$  sunt albe și  $b$  sunt negre ( $a+b=c$ ). Se extrage o bilă, i se înregistrează culoarea, iar apoi se reintroduce în urnă. Se repetă această experiență de  $n$  ori. Se studiază probabilitatea evenimentului  $A_{k|n}$  al apariției bilei albe de  $k$  ori în cele  $n$  extrageri (cu repunerea bilei în urnă).

Notăm  $\mathbb{P}_{k|n} = \mathbb{P}(A_{k|n})$  probabilitatea evenimentului menționat. Un raționament elementar ne conduce la formula de calcul

$$\mathbb{P}_{k|n} = C_n^k p^k q^{n-k}, \quad k = 0, 1, \dots, n,$$

unde  $p = a/c$  este probabilitatea apariției unei bile la o extragere, iar  $q = b/c = 1 - p$  este probabilitatea evenimentului contrar (apariția unei bile negre).

Modelul este echivalent cu repetarea unei experiențe (în condiții identice) de  $n$  ori și studiul probabilității realizării unui anumit eveniment de  $k$  ori (din totalul de  $n$  experiențe).

Remarcăm

$$\sum_{k=0}^n \mathbb{P}(A_{k|n}) = \sum_{k=0}^n \mathbb{P}_{k|n} = \sum_{k=0}^n C_n^k p^k q^{n-k} = (q + p)^n = 1,$$

deci evenimentele  $A_{k|n}$ ,  $k = 0, 1, \dots, n$ , reprezintă un sistem complet.

### 2. Schema multinomială.

Este o extindere a schemei lui Bernoulli.

Se consideră o urnă conținând bile de  $s$  culori, câte  $a_i$  bile din culoarea  $i \in \{1, 2, \dots, s\}$ .

Notăm

$$p_i = \frac{a_i}{\sum_{j=1}^s a_j}$$

probabilitatea extragerii unei bile de culoarea  $i \in \{1, 2, \dots, s\}$ . Se fac  $n$  extrageri, cu repunerea bilei în urnă după fiecare extragere. Fie  $(k_i)_{i=\overline{1,s}}$  un vector de dimensiune  $s$ , cu componente naturale, având proprietatea  $\sum_{i=1}^s k_i = n$ . Notăm

$$\mathbb{P}_{(k_i)_{i=\overline{1,s}}|n}$$

probabilitatea evenimentului  $A_{(k_i)_{i=\overline{1,s}}|n}$  de extragere a exact  $k_i$  bile de culoarea  $i$ , unde  $i = 1, 2, \dots, s$ , din totalul de  $n$  bile extrase. Se constată că

$$\mathbb{P}_{(k_i)_{i=\overline{1,s}}|n} = \binom{n}{k_1, k_2, \dots, k_s} p_1^{k_1} p_2^{k_2} \dots p_s^{k_s},$$

unde

$$\binom{n}{k_1, k_2, \dots, k_s} = \frac{n!}{k_1! k_2! \dots k_s!}$$

reprezintă combinările multinomiale de  $n$  luate câte  $k_1, k_2, \dots, k_s$ .

Avem

$$\sum_{(k_i) \in \mathbb{N}^s; \sum_{i=1}^s k_i = n} \mathbb{P}_{(k_i)_{i=\overline{1,s}}|n} = \sum_{(k_i) \in \mathbb{N}^s; \sum_{i=1}^s k_i = n} \binom{n}{k_1, k_2, \dots, k_s} p_1^{k_1} p_2^{k_2} \dots p_s^{k_s} =$$

$$= (p_1 + p_2 + \cdots + p_s)^n = 1,$$

deci  $A_{(k_i)_{i=1,s}|n}$ , cu  $(k_i) \in \mathbb{N}^s$ , astfel ca  $\sum_{i=1}^s k_i = n$ , formează un sistem complet de evenimente.

### 3. Schema lui Poisson.

Reprezintă o generalizare a schemei lui Bernoulli. Se consideră  $n$  urne cu bile albe și negre, dar în proporții diferite. Fie  $p_i$  probabilitatea extragerii unei bile albe din urna  $i$ . Probabilitatea extragerii unei bile negre din urna  $i$  va fi  $q_i = 1 - p_i$ ,  $i = 1, 2, \dots, n$ . Se extrage câte o bilă din fiecare urnă. Se analizează probabilitatea evenimentului  $A_{k|n}$  de a obține exact  $k$  bile albe din cele  $n$  extrase. Notăm  $\mathbb{N}_n = \{1, 2, \dots, n\}$ . Avem

$$\mathbb{P}_{k|n} = \mathbb{P}(A_{k|n}) = \sum_{I \subset \mathbb{N}_n; |I|=k} \prod_{i \in I} p_i \prod_{j \in \mathbb{N}_n \setminus I} q_j.$$

Observăm că  $\mathbb{P}_{k|n}$  reprezintă coeficientul lui  $x^k$  al polinomului

$$f(x) = (p_1x + q_1)(p_2x + q_2) \cdots (p_nx + q_n).$$

Evident,

$$\sum_{k=0}^n \mathbb{P}_{k|n} = f(1) = 1,$$

deci evenimentele  $A_{k|n}$ ,  $k = 0, 1, \dots, n$ , reprezintă un sistem complet.

### 4. Schema geometrică.

Schema este un exemplu de câmp discret de evenimente. Astfel, se repetă continuu o experiență, în condiții identice, urmărindu-se de fiecare dată realizarea unui anumit eveniment  $A$ . Fie  $\mathbb{P}(A) = p$ . Considerăm momentul în care evenimentul  $A$  se realizează pentru prima dată. Fie  $n \in \mathbb{N}^*$ . Probabilitatea ca evenimentul  $A$  să se realizeze pentru prima dată în cea de a  $n$ -a experiență este

$$p_n = pq^{n-1},$$

unde  $q = 1 - p$ . Avem

$$\sum_{n=1}^{\infty} p_n = \sum_{n=1}^{\infty} pq^{n-1} = p \sum_{k=0}^{\infty} q^k = \frac{p}{1-q} = 1.$$

### 5. Schema hipergeometrică.

Se consideră o urnă cu  $N$  bile, dintre care  $a$  bile sunt albe iar restul de  $b$  bile sunt negre ( $a + b = N$ ). Se extrag  $n$  bile (fără a le repune în urmă după fiecare extragere). Notăm  $p_{k|n}$  probabilitatea evenimentului  $A_{k|n}$  de a avea exact  $k$  bile albe între cele  $n$  bile extrase. Presupunem  $n \leq N$ ,  $k \leq a$  și  $n - k \leq b$ . Atunci

$$p_{k|n} = \frac{C_a^k C_b^{n-k}}{C_N^n}.$$

Conform unei formule combinatoriale binecunoscute, obținem

$$\sum_{k=\max\{0, n-b\}}^{\min\{a, n\}} p_{k|n} = \sum_{k=\max\{0, n-b\}}^{\min\{a, n\}} \frac{C_a^k C_b^{n-k}}{C_N^n} = 1,$$



deci  $A_{k|n}$ ,  $\max\{0, n - b\} \leq k \leq \min\{a, n\}$ , formează un sistem complet de evenimente.

6. *Schema hipergeometrică generalizată.*

Se consideră o urnă cu  $N$  bile de  $s$  culori. Fie  $a_i$  numărul de bile de culoarea  $i$ ,  $i = 1, 2, \dots, s$ . Avem deci  $\sum_{i=1}^s a_i = N$ . Se extrag, fără repunere,  $n$  bile. Considerăm vectorul  $(k_i) \in \mathbb{N}^s$ , cu  $\sum_{i=1}^s k_i = n$ , astfel încât  $k_i \leq a_i$ ,  $i = 1, 2, \dots, s$ . Atunci probabilitatea extragerii a  $k_i$  bile din culoarea  $i$ , pentru fiecare  $i \in \{1, 2, \dots, s\}$ , este

$$p(k_i) = \frac{C_{a_1}^{k_1} C_{a_2}^{k_2} \dots C_{a_s}^{k_s}}{C_N^n}.$$

## 1.8 Rezumat

În teoria probabilităților, evenimentele rezultate în urma unei experiențe sunt interpretate ca o familie de submulțimi ale evenimentului sigur, mulțimea  $\Omega$ . Mulțimea evenimentelor formează un  $\sigma$ -corp (borelian).

O mulțime nevidă  $\mathcal{F} \subset \Omega$  se numește  $\sigma$ -corp a lui  $\Omega$  dacă satisface următoarele condiții:

$$\sigma_1. A^c \in \mathcal{F}, \forall A \in \mathcal{F};$$

$$\sigma_2. \text{ dacă } A_n \in \mathcal{F}, \forall n \in \mathbb{N}^* \text{ atunci } \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}.$$

Perechea  $(\Omega, \mathcal{F})$  se numește spațiu măsurabil sau câmp de evenimente.

Borelianul lui  $\Omega = \mathbb{R}$ , notat  $\mathcal{B}_{\mathbb{R}}$  este  $\sigma$ -corpul generat de mulțimile deschise (topologia lui  $\mathbb{R}$ ), adică cel mai mic  $\sigma$ -corp a lui  $\mathbb{R}$  care include mulțimile deschise.  $\mathcal{B}_{\mathbb{R}}$  conține toate tipurile de intervale și este generat de oricare tip de intervale reale.

Fie  $(\Omega, \mathcal{F})$  și  $(\Omega', \mathcal{F}')$  o pereche de spații măsurabile (câmpuri de evenimente). O funcție  $f : \Omega \rightarrow \Omega'$  se numește *funcție măsurabilă* dacă

$$f^{-1}(A) \in \mathcal{F}, \forall A \in \mathcal{F}',$$

unde  $f^{-1}(A) = \{\omega \in \Omega \mid f(\omega) \in A\}$ .

În particular, dacă  $\Omega' = \mathbb{R}$  și  $\mathcal{F}' = \mathcal{B}_{\mathbb{R}}$ , funcția  $f$  se va numi *funcție reală măsurabilă*. Pentru o funcție reală măsurabilă  $f : \Omega \rightarrow \mathbb{R}$ , avem:

- $\{f \leq a\} := f^{-1}((-\infty, a]) \in \mathcal{F}, \forall a \in \mathbb{R}$
- $\{f > a\} := f^{-1}((a, \infty)) \in \mathcal{F}, \forall a \in \mathbb{R}$
- $\{a \leq f \leq b\} := f^{-1}([a, b]) \in \mathcal{F}, \forall a, b \in \mathbb{R}, a < b.$

Dacă  $f, g : \Omega \rightarrow \mathbb{R}$  sunt funcții reale măsurabile și  $a \in \mathbb{R}$  atunci funcțiile reale  $f + a$ ,  $af$ ,  $|f|$ ,  $f + g$ ,  $fg$ ,  $\min\{f, g\}$  și  $\max\{f, g\}$  sunt măsurabile.

Fie  $(\Omega, \mathcal{F})$  un spațiu măsurabil, cu  $\sigma$ -corpul  $\mathcal{F}$  denumit "mulțimea evenimentelor". O funcție  $\mathbb{P} : \mathcal{F} \rightarrow \mathbb{R}$  se numește probabilitate dacă satisface următoarele axiome:

$$P1. \mathbb{P}(A) \geq 0, \forall A \in \mathcal{F};$$

$$P2. \mathbb{P}(\Omega) = 1;$$

P3. Pentru oricare șir de evenimente  $(A_n)_{n \in \mathbb{N}^*}$ , cu  $A_n \cap A_m = \emptyset, \forall n \neq m$ , are loc relația

$$\mathbb{P}(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Tripletul  $(\Omega, \mathcal{F}, \mathbb{P})$  se numește câmp de probabilitate.

Probabilitatea are proprietățile:

$$P4. \mathbb{P}(\emptyset) = 0;$$

$$P5. \mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B), \forall A, B \in \mathcal{F}, A \cap B = \emptyset;$$

P6.  $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$ ,  $\forall A \in \mathcal{F}$ ;

P7.  $\mathbb{P}(A \setminus B) = \mathbb{P}(A) - \mathbb{P}(B)$ ,  $\forall A, B \in \mathcal{F}$ ,  $B \subset A$ ;

P8.  $\mathbb{P}(A) \leq \mathbb{P}(B)$ ,  $\forall A, B \in \mathcal{F}$ ,  $A \subset B$ ;

P9.  $\mathbb{P}(A) \in [0, 1]$ ,  $\forall A \in \mathcal{F}$ ;

P10. (Formula lui Poincaré)

$$\mathbb{P}(\cup_{i=1}^n A_i) = \sum_{k=1}^n (-1)^{k+1} \sum_{1 \leq i_1 < i_2 < \dots < i_k \leq n} \mathbb{P}(\cap_{j=1}^k A_{i_j});$$

P11. Dacă  $(A_n)_{n \geq 1}$  este un șir monoton (crescător sau descrescător) de evenimente, cu  $\lim_{n \rightarrow \infty} A_n = A$ , atunci  $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \mathbb{P}(A)$ .

P12. Pentru oricare șir de evenimente  $(A_n)_{n \in \mathbb{N}^*}$  avem

$$\mathbb{P}(\cup_{n=1}^{\infty} A_n) \leq \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Considerăm un eveniment  $A \in \mathcal{F}$ , cu  $\mathbb{P}(A) > 0$ . Pentru oricare eveniment  $B \in \mathcal{F}$ , numim probabilitatea lui  $B$  condiționată de (realizarea evenimentului)  $A$  mărimea:

$$\mathbb{P}(B|A) := \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)}.$$

Evenimentele  $A$  și  $B$  se numesc independente dacă  $\mathbb{P}(B|A) = \mathbb{P}(B)$ , adică  $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ .

Mai general,  $\mathcal{G} \subset \mathcal{F}$  se numește familie de evenimente independente dacă pentru oricare evenimente distincte  $A_1, A_2, \dots, A_n \in \mathcal{G}$  avem

$$\mathbb{P}(\cap_{i=1}^n A_i) = \prod_{i=1}^n \mathbb{P}(A_i).$$

Astfel, două evenimente sunt independente dacă probabilitatea realizării unuia dintre acestea nu este influențată de realizarea celuilalt.

Evenimentele  $A_i$ ,  $i \in I$ , unde  $I$  este o mulțime cel mult numărabilă de indici, formează un sistem complet de evenimente în câmpul de probabilitate  $(\Omega, \mathcal{F}, \mathbb{P})$  dacă:

1.  $A_i \cap A_j = \emptyset$ ,  $\forall i \neq j$
2.  $\cup_{i \in I} A_i = \Omega$
3.  $\mathbb{P}(A_i) > 0$ ,  $\forall i \in I$

Dacă  $A$  este un eveniment cu probabilitate nenulă (neneglijabil), atunci loc:

1. Formula probabilității totale

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A|A_i)\mathbb{P}(A_i)$$

## 2. Formula lui Bayes

$$\mathbb{P}(A_k|A) = \frac{\mathbb{P}(A|A_k)\mathbb{P}(A_k)}{\sum_{i \in I} \mathbb{P}(A|A_i)\mathbb{P}(A_i)}, \quad \forall k \in I.$$

Modelele de bază de câmpuri de probabilitate discrete:

### 1. Câmpul lui Laplace.

Spațiul  $\Omega$  este considerat o mulțime finită, iar  $\sigma$ -corpul  $\mathcal{F}$  este considerat mulțimea  $\mathcal{P}(\Omega)$  (mulțimea submulțimilor lui  $\Omega$ ). Probabilitatea unui eveniment  $A \subset \Omega$  se definește prin:

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|},$$

unde  $|M|$  reprezintă numărul elementelor unei mulțimi finite  $M$ . Elementele lui  $\Omega$  determină evenimentele *elementare*, *echiprobabile*. Astfel, pentru  $\omega \in \Omega$ , avem

$$\mathbb{P}(\{\omega\}) = \frac{1}{n},$$

unde  $n = |\Omega|$ .

### 2. Câmp discret de evenimente.

Considerăm  $\Omega = \{\omega_i : i \in I\}$ , unde mulțimea de indici  $I$  este cel mult numărabilă. Definim  $\mathcal{F} = \mathcal{P}(\Omega)$ . Considerăm o măsură de probabilitate  $(p_i)_{i \in I}$  pe mulțimea  $\Omega$ , unde  $p_i \geq 0$ ,  $\forall i \in I$  și  $\sum_{i \in I} p_i = 1$ . Probabilitatea unui eveniment  $A = \{\omega_j : j \in J\}$ , cu  $J \subset I$ , se definește prin

$$\mathbb{P}(A) = \sum_{j \in J} p_j.$$

**Schemele de probabilitate** reprezintă modele/exemple cu un grad mare de generalitate în calculul probabilităților.

### 1. Schema lui Bernoulli.

Este un exemplu de câmp Laplace. Schema modelează următoarea experiență:

O urnă conține  $c$  bile, dintre care  $a$  sunt albe și  $b$  sunt negre ( $a+b=c$ ). Se extrage o bilă, i se înregistrează culoarea, iar apoi se reintroduce în urnă. Se repetă această experiență de  $n$  ori. Se studiază probabilitatea evenimentului  $A_{k|n}$  al apariției bilei albe de  $k$  ori din cele  $n$  extrageri (cu repunerea bilei în urnă).

Notăm  $\mathbb{P}_{k|n} = \mathbb{P}(A_{k|n})$  probabilitatea evenimentului menționat. Avem

$$\mathbb{P}_{k|n} = C_n^k p^k q^{n-k}, \quad k = 0, 1, \dots, n,$$

unde  $p = a/c$  este probabilitatea apariției unei bile la o extragere, iar  $q = b/c = 1 - p$  este probabilitatea evenimentului contrar (apariția unei bile negre).

### 2. Schema multinomială.

Este o extindere a schemei lui Bernoulli.

Se consideră o urnă conținând bile de  $s$  culori, câte  $a_i$  bile din culoarea  $i \in \{1, 2, \dots, s\}$ .

Notăm

$$p_i = \frac{a_i}{\sum_{j=1}^s a_j}$$

probabilitatea extragerii unei bile de culoarea  $i \in \{1, 2, \dots, s\}$ . Se fac  $n$  extrageri, cu repunerea bilei în urnă după fiecare extragere. Fie  $(k_i)_{i=\overline{1,s}}$  un vector de dimensiune  $s$ , cu componente naturale, având proprietatea  $\sum_{i=1}^s k_i = n$ . Notăm

$$\mathbb{P}_{(k_i)_{i=\overline{1,s}}|n}$$

probabilitatea evenimentului  $A_{(k_i)_{i=\overline{1,s}}|n}$  de extragere a exact  $k_i$  bile de culoarea  $i$ , unde  $i = 1, 2, \dots, s$ , din totalul de  $n$  bile extrase. Avem

$$\mathbb{P}_{(k_i)_{i=\overline{1,s}}|n} = \binom{n}{k_1, k_2, \dots, k_s} p_1^{k_1} p_2^{k_2} \cdots p_s^{k_s},$$

unde

$$\binom{n}{k_1, k_2, \dots, k_s} = \frac{n!}{k_1! k_2! \cdots k_s!}$$

reprezintă combinările multinomiale de  $n$  luate câte  $k_1, k_2, \dots, k_s$ .

### 3. Schema lui Poisson.

Reprezintă o generalizare a schemei lui Bernoulli. Se consideră  $n$  urne cu bile albe și negre, dar în proporții diferite. Fie  $p_i$  probabilitatea extragerii unei bile albe din urna  $i$ . Probabilitatea extragerii unei bile negre din urna  $i$  va fi  $q_i = 1 - p_i$ ,  $i = 1, 2, \dots, n$ . Se extrage câte o bilă din fiecare urnă. Se analizează probabilitatea evenimentului  $A_{k|n}$  de a obține exact  $k$  bile albe din cele  $n$  extrase. Notăm  $\mathbb{N}_n = \{1, 2, \dots, n\}$ . Avem

$$\mathbb{P}_{k|n} = \mathbb{P}(A_{k|n}) = \sum_{I \subset \mathbb{N}_n; |I|=k} \prod_{i \in I} p_i \prod_{j \in \mathbb{N}_n \setminus I} q_j.$$

Observăm că  $\mathbb{P}_{k|n}$  reprezintă coeficientul lui  $x^k$  al polinomului

$$f(x) = (p_1x + q_1)(p_2x + q_2) \cdots (p_nx + q_n).$$

### 4. Schema geometrică.

Schema este un exemplu de câmp discret de evenimente. Astfel, se repetă continuu o experiență, în condiții identice, urmărindu-se de fiecare dată realizarea unui anumit eveniment  $A$ . Fie  $\mathbb{P}(A) = p$ . Considerăm momentul în care evenimentul  $A$  se realizează pentru prima dată. Fie  $n \in \mathbb{N}^*$ . Probabilitatea ca evenimentul  $A$  să se realizeze pentru prima dată în cea de a  $n$ -a experiență este

$$p_n = pq^{n-1},$$

unde  $q = 1 - p$ .

### 5. Schema hipergeometrică.

Se consideră o urnă cu  $N$  bile, dintre care  $a$  bile sunt albe iar restul de  $b$  bile sunt negre ( $a + b = N$ ). Se extrag  $n$  bile (fără a le repune în urmă după fiecare extragere). Notăm  $p_{k|n}$  probabilitatea evenimentului  $A_{k|n}$  de a avea exact  $k$  bile albe între cele  $n$  bile extrase. Presupunem  $n \leq N$ ,  $k \leq a$  și  $n - k \leq b$ . Atunci

$$p_{k|n} = \frac{C_a^k C_b^{n-k}}{C_N^n}.$$

## 1.9 Test

1. Definiți noțiunea de evenimente condiționate. Enunțați și demonstrați formula probabilității totale.
2. Aplicați formula lui Poincaré pentru  $n$  evenimente independente, echiprobabile, de probabilitate  $p \in (0, 1)$ .
3. Fie  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmp de probabilitate și evenimentele  $A, B \in \mathcal{F}$ . Știind că  $\mathbb{P}(A) = 1/5$ ,  $\mathbb{P}(B) = 3/5$  și  $\mathbb{P}(A \cap B) = 1/10$ , să se calculeze probabilitățile:
  - (a)  $\mathbb{P}(A \cup B)$ ;
  - (b)  $\mathbb{P}(A \cap \overline{B})$ ;
  - (c)  $\mathbb{P}(A|B) = \mathbb{P}_B(A)$ .
4. Un sportiv trage la o țintă cu 5 puști diferite, cu probabilitățile respective de ochire:  $p_1 = 0,8$ ,  $p_2 = 0,7$ ,  $p_3 = 0,4$ ,  $p_4 = 0,9$  și  $p_5 = 0,5$ . Să se calculeze:
  - (a) probabilitatea ca ținta să fie nimerită de exact 3 ori;
  - (b) probabilitatea ca ținta să nimerită cel puțin o dată.
5. Un portar apără o lovitură de la 11 metri cu probabilitatea  $p = 0,3$ . La finalul unui meci, se execută 5 lovituri de la 11 metri.
  - (a) Care este probabilitatea ca portarul respectiv să apere exact 2 lovituri?
  - (b) Care este cel mai probabil număr de goluri primite?
6. Care este probabilitatea de a nimeri exact doua numere la jocul *Loto 6 din 49*, dacă se joacă o singură variantă?
7. Un baschetbalist execută aruncări de la distanță la un panou de baschet, până la prima reușită. Știind că șansa de reușită a fiecărei aruncări este de 20%, să se determine probabilitatea ca sportivul să înscrie primul coș din a patra aruncare. Care este cel mai probabil număr de aruncări până la prima reușită?

# Capitolul 2

## Variabile aleatoare. Caracteristici numerice

### 2.1 Introducere

### 2.2 Variabile aleatoare

Variabilele aleatoare se interpretează ca o "enumerare" a rezultatelor (măsurabile) potențiale ale unui anumit experiment. Fiecare din aceste rezultate posibile are o probabilitate de realizare. Definiția de mai jos formalizează matematic un experiment cu rezultate aleatoare, predictibile.

**Definiția 2.2.1.** Fie  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmp de probabilitate. O funcție măsurabilă reală  $X : \Omega \rightarrow \mathbb{R}$  se numește variabilă aleatoare (reală).

Conform definiției, pentru o variabilă aleatoare  $X$  definită pe câmpul de probabilitate  $(\Omega, \mathcal{F}, \mathbb{P})$ , avem

$$\{X \in I\} \in \mathcal{F},$$

pentru orice interval real  $I$ . În particular,

$$\{X \in (-\infty, a]\} = \{X \leq a\} \in \mathcal{F}, \quad \forall a \in \mathbb{R}.$$

Probabilitățile evenimentelor descrise mai sus oferă o informație fundamentală privind variabila aleatoare. În fapt, cunoașterea probabilităților evenimentelor  $\{X \leq a\}$ ,  $a \in \mathbb{R}$ , oferă o informație precisă privind distribuția valorilor variabilei aleatoare  $X$ . În secțiunea următoare, va fi introdusă și caracterizată funcția de repartiție a unei variabile aleatoare, construită pe baza probabilităților menționate.

O mulțime finită de variabile aleatoare definite pe același câmp de probabilitate va determina un vector aleator. Mai precis, avem următoarea definiție.

**Definiția 2.2.2.** Fie  $d > 1$  un număr întreg și  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmp de probabilitate. Considerăm borelianul  $\mathcal{B}_{\mathbb{R}^d}$  spațiului  $\mathbb{R}^d$  ( $\sigma$  – corpul generat de topologia lui  $\mathbb{R}^d$ ). O funcție  $X : \Omega \rightarrow \mathbb{R}^d$ ,  $(\mathcal{F}, \mathcal{B}_{\mathbb{R}^d})$  măsurabilă, se numește vector aleator.

Fie  $X_i$ ,  $i = 1, 2, \dots, d$ , componentele scalare ale funcției  $X$ , deci  $X = (X_1, X_2, \dots, X_d)$ . Conform definiției de mai sus,

$$\{X_1 \leq a_1, X_2 \leq a_2, \dots, X_d \leq a_d\} \in \mathcal{F}, \quad \forall (a_1, a_2, \dots, a_d) \in \mathbb{R}^d.$$

## 2.3 Funcția de repartiție

Distribuția valorilor unei variabile aleatoare reale este caracterizată prin noțiunea de funcție de repartiție. De regulă, câmpul de probabilitate pe care este definită variabila aleatoare nu este menționat în mod explicit.

**Definiția 2.3.1.** Fie  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmp de probabilitate și  $X : \Omega \rightarrow \mathbb{R}$  o variabilă aleatoare. Funcția reală  $F : \mathbb{R} \rightarrow [0, 1]$ , definită prin

$$F(x) = \mathbb{P}\{X \leq x\} = \mathbb{P}(\{\omega \in \Omega : X(\omega) \leq x\}), \quad x \in \mathbb{R},$$

se numește funcția de repartiție a variabilei aleatoare  $X$ .

Propoziția următoare grupează proprietățile de bază ale unei funcții de repartiție.

**Propoziția 2.3.1.** Fie  $F : \mathbb{R} \rightarrow [0, 1]$  funcția de repartiție a unei variabile aleatoare  $X$ . Au loc următoarele proprietăți cu caracter general.

1.  $F$  este monoton crescătoare pe  $\mathbb{R}$ ;
2.  $F$  este continuă la dreapta pe mulțimea  $\mathbb{R}$  ( $F(x+0) := \lim_{t \downarrow x} F(t) = F(x)$ ,  $\forall x \in \mathbb{R}$ );
3.  $\lim_{x \rightarrow -\infty} F(x) = 0$ ;  $\lim_{x \rightarrow \infty} F(x) = 1$ ;
4.  $F(x-0) := \lim_{t \uparrow x} F(t) = \mathbb{P}\{X < x\}$ ,  $\forall x \in \mathbb{R}$ ;
5.  $\mathbb{P}\{X = x\} = F(x) - F(x-0)$ ,  $\forall x \in \mathbb{R}$ ;
6.  $\mathbb{P}\{a < X \leq b\} = F(b) - F(a)$ ,  $\forall a, b \in \mathbb{R}$ , cu  $a < b$ ;
7.  $\mathbb{P}\{X > x\} = 1 - F(x)$ ,  $\forall x \in \mathbb{R}$ .

*Demonstrație.* Fie  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmpul de probabilitate pe care este definită variabila aleatoare  $X$ .

1. Fie  $x_1, x_2 \in \mathbb{R}$ , cu  $x_1 < x_2$ . Avem  $\{X \leq x_1\} \subset \{X \leq x_2\}$ , de unde  $\mathbb{P}\{X \leq x_1\} \leq \mathbb{P}\{X \leq x_2\}$ , sau  $F(x_1) \leq F(x_2)$ .
2. Fiind monoton crescătoare pe  $\mathbb{R}$ , funcția  $F$  admite limite laterale finite pe  $\mathbb{R}$ . Mai precis, pentru  $x \in \mathbb{R}$ , limita la stânga în  $x$  este  $F(x-0) = \sup_{t < x} F(t)$ , iar limita la dreapta în  $x$  este  $F(x+0) = \inf_{t > x} F(t)$ . Evident,

$$F(x-0) \leq F(x) \leq F(x+0), \quad \forall x \in \mathbb{R}.$$

Fixăm  $x \in \mathbb{R}$ , arbitrar. Notăm  $A_n = \{X \leq x + \frac{1}{n}\} \in \mathcal{F}$ ,  $n \in \mathbb{N}^*$ . Fie  $A = \{X \leq x\}$ . Avem  $A = \bigcap_{n=1}^{\infty} A_n$  și  $A_n \downarrow A$ . Conform Propoziției 1.5.1, avem  $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \mathbb{P}(A)$ . Dar,  $\mathbb{P}(A) = F(x)$  și  $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \lim_{n \rightarrow \infty} F(x + \frac{1}{n}) = F(x+0)$ . Obținem  $F(x+0) = F(x)$ , deci  $F$  este continuă la dreapta în  $x$ .

3. Conform monotoniei,  $F$  admite limite finite la  $\infty$  și  $-\infty$ . Astfel,  $\lim_{x \rightarrow -\infty} F(x) = \inf_{x \in \mathbb{R}} F(x) \geq 0$  și  $\lim_{x \rightarrow \infty} F(x) = \sup_{x \in \mathbb{R}} F(x) \leq 1$ . Fie  $B_n = \{X \leq -n\}$ ,  $C_n = \{X \leq n\}$ ,  $n \in \mathbb{N}^*$ . Avem  $B_n \downarrow \emptyset$ , respectiv  $C_n \uparrow \Omega$ . Ca urmare,

$$\lim_{x \rightarrow -\infty} F(x) = \lim_{n \rightarrow \infty} F(-n) = \lim_{n \rightarrow \infty} \mathbb{P}(B_n) = \mathbb{P}(\emptyset) = 0,$$



respectiv

$$\lim_{x \rightarrow \infty} F(x) = \lim_{n \rightarrow \infty} F(n) = \lim_{n \rightarrow \infty} \mathbb{P}(C_n) = \mathbb{P}(\Omega) = 1.$$

4. Fie  $x \in \mathbb{R}$ , arbitrar, fixat. Conform proprietăților unei funcții monoton crescătoare și Propoziției 1.5.1, avem

$$F(x - 0) = \lim_{t \uparrow x} F(t) = \lim_{n \rightarrow \infty} F\left(x - \frac{1}{n}\right) = \lim_{n \rightarrow \infty} \mathbb{P}\left\{X \leq x - \frac{1}{n}\right\} = \mathbb{P}\{X < x\}.$$

5. Pentru  $x \in \mathbb{R}$ , avem

$$\mathbb{P}\{X = x\} = \mathbb{P}(\{X \leq x\} \setminus \{X < x\}) = \mathbb{P}\{X \leq x\} - \mathbb{P}\{X < x\} = F(x) - F(x - 0).$$

6. Fie  $a, b \in \mathbb{R}$ ,  $a < b$ . Avem  $\{a < X \leq b\} = \{X \leq b\} \setminus \{X \leq a\}$  și  $\{X \leq a\} \subset \{X \leq b\}$ . Atunci, conform Propoziției 1.5.1,

$$\mathbb{P}\{a < X \leq b\} = \mathbb{P}\{X \leq b\} - \mathbb{P}\{X \leq a\} = F(b) - F(a).$$

7. Fie  $x \in \mathbb{R}$ . Avem  $\mathbb{P}\{X > x\} = \mathbb{P}\{X \leq x\}^c = 1 - \mathbb{P}\{X \leq x\} = 1 - F(x)$ .  $\square$

Din propoziția de mai sus rezultă că, dacă  $F$  este continuă în  $x_0 \in \mathbb{R}$ , atunci  $\mathbb{P}\{X = x_0\} = 0$ . Menționăm că, reciproc, orice funcție  $F : \mathbb{R} \rightarrow [0, 1]$  care satisface proprietățile 1-3 din Propoziția 2.3.1 este funcția de repartiție a unei anumite variabile aleatoare. Două sau mai multe variabile aleatoare care admit o funcție de repartiție comună vor fi denumite *identic distribuite*.

De asemenea, putem defini funcția de repartiție a unui vector aleator, având proprietăți generale apropiate de cele ale funcției de repartiție a unei variabile aleatoare.

**Definiția 2.3.2.** Fie  $X = (X_1, X_2, \dots, X_d)$  un vector aleator. Definim funcția sa de repartiție prin  $F : \mathbb{R}^d \rightarrow [0, 1]$ ,

$$F(x_1, x_2, \dots, x_d) = \mathbb{P}\{X_1 \leq x_1, X_2 \leq x_2, \dots, X_d \leq x_d\}, \quad (x_1, x_2, \dots, x_d) \in \mathbb{R}^d.$$

O noțiune importantă este *independența variabilelor aleatoare*, definită mai jos.

**Definiția 2.3.3.** Variabilele aleatoare  $X_i$ ,  $i \in I$ , definite pe un câmp de probabilitate  $(\Omega, \mathcal{F}, \mathbb{P})$ , se numesc *independente* dacă, pentru oricare oricare indici distincți  $i_1, i_2, \dots, i_n$  din mulțimea  $I$  și oricare  $A_1, A_2, \dots, A_n \in \mathcal{B}_{\mathbb{R}}$  are loc

$$\mathbb{P}\{X_{i_1} \in A_1, X_{i_2} \in A_2, \dots, X_{i_n} \in A_n\} = \mathbb{P}\{X_{i_1} \in A_1\} \mathbb{P}\{X_{i_2} \in A_2\} \cdots \mathbb{P}\{X_{i_n} \in A_n\}.$$

În particular, dacă variabilele aleatoare  $X_1, X_2, \dots, X_n$ , având, respectiv, funcțiile de repartiție  $F_1, F_2, \dots, F_n$ , sunt independente, atunci

$$\mathbb{P}\{X_1 \leq a_1, X_2 \leq a_2, \dots, X_n \leq a_n\} = F_1(a_1)F_2(a_2) \cdots F_n(a_n), \quad \forall a_1, a_2, \dots, a_n \in \mathbb{R}.$$

Are loc următorul rezultat de bază privind suma a două variabile aleatoare independente.

**Propoziția 2.3.2.** Fie variabilele aleatoare independente  $X$  și  $Y$ , având funcțiile de repartiție  $F$  și respectiv  $G$ . Atunci funcția de repartiție a variabilei aleatoare  $Z = X + Y$  este  $H = F * G$ , unde

$$(F * G)(x) = \int_{-\infty}^{\infty} F(x-t)dG(t), \quad \forall x \in \mathbb{R}.$$

Variabilele aleatoare cu valori într-o mulțime cel mult numărabilă se numesc *discrete*. Variabilele aleatoare cu funcția de repartiție derivabilă, cu derivata continuă, se numesc *continue*. În secțiunea următoare vom discuta aceste tipuri particulare, dar deosebit de importante, de variabile aleatoare. Vom ilustra cele două tipuri de variabile aleatoare (discrete și continue) prin exemple clasice, semnificative.

## 2.4 Variabile aleatoare discrete. Exemple clasice

În cele ce urmează, definim, caracterizăm și exemplificăm variabilele aleatoare de tip discret.

**Definiția 2.4.1.** Fie  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmp de probabilitate și  $X : \Omega \rightarrow \mathbb{R}$  o variabilă aleatoare.  $X$  se numește variabilă aleatoare discretă dacă mulțimea  $X(\Omega)$  este cel mult numărabilă.

Fie  $X(\Omega) = \{x_i, i \in I\} \subset \mathbb{R}$ , unde  $I$  este o mulțime de indici cel mult numărabilă. Notăm  $A_i = \{X = x_i\} \in \mathcal{F}$ ,  $i \in I$ . Remarcăm că familia de evenimente  $\{A_i, i \in I\}$  reprezintă o partiție a spațiului  $\Omega$ .

Pentru  $A \in \mathcal{F}$ , notăm prin  $c_A : \Omega \rightarrow \mathbb{R}$  funcția caracteristică a mulțimii  $A$ , definită prin

$$c_A(\omega) = \begin{cases} 1, & \omega \in A \\ 0, & \omega \in \Omega \setminus A = A^c \end{cases}.$$

Este elementar de verificat faptul că funcția caracteristică a unui eveniment este o variabilă aleatoare. Are loc următoarea reprezentare a variabilei aleatoare discrete  $X$ :

$$X = \sum_{i \in I} x_i c_{A_i}.$$

Notuăm  $p_i = \mathbb{P}(A_i)$ ,  $i \in I$ . Avem  $p_i \geq 0$ ,  $\forall i \in I$  și  $\sum_{i \in I} p_i = 1$ .

Distribuția variabilei aleatoare  $X$  se reprezintă convențional astfel:

$$X : \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}.$$

Fie variabilele aleatoare discrete, independente,  $X$  și  $Y$ , cu distribuțiile

$$X : \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}, \quad Y : \begin{pmatrix} y_j \\ p'_j \end{pmatrix}_{j \in J}.$$

Atunci variabila aleatoare  $X + Y$  va avea distribuția

$$X + Y : \begin{pmatrix} x_i + y_j \\ p_i p'_j \end{pmatrix}_{(i,j) \in I \times J}.$$

**Exemplul 2.4.1.** *Variabile aleatoare Bernoulli.*

O variabilă aleatoare Bernoulli  $X$  ia doar două valori: valoarea 1, cu probabilitatea  $p \in (0, 1)$  și valoarea 0, cu probabilitatea  $q = 1 - p$ . Distribuția lui  $X$  se reprezintă astfel:

$$X : \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}.$$

Notăm  $X \in \text{Bin}(1, p)$ .

**Exemplul 2.4.2.** *Variabile aleatoare binomiale.*

O variabilă aleatoare binomială  $X$ , de parametrii  $n \in \mathbb{N}^*$  și  $p \in (0, 1)$  ia valorile  $k \in \{0, 1, \dots, n\}$  cu probabilitățile  $p_k = C_n^k p^k q^{n-k}$ . Distribuția lui  $X$  se reprezintă astfel:

$$X : \begin{pmatrix} 0 & 1 & 2 & \dots & n \\ C_n^0 q^n & C_n^1 p q^{n-1} & C_n^2 p^2 q^{n-2} & \dots & C_n^n p^n \end{pmatrix}.$$

Variabila aleatoare binomială indică numărul de realizări ale unui eveniment având probabilitatea  $p$  în  $n$  experiențe identice, independente (schema binomială - Bernoulli). Notăm  $X \in \text{Bin}(n, p)$ .

Este important de remarcat că o variabilă aleatoare binomială de parametrii  $(n, p)$  este suma a  $n$  variabile aleatoare Bernoulli independente, identic distribuite (de parametru  $p$ ).

**Exemplul 2.4.3.** *Variabile aleatoare Poisson.*

O variabilă aleatoare Poisson de parametru  $\lambda$  ia valoarea  $n$  cu probabilitatea  $\frac{\lambda^n}{n!} e^{-\lambda}$ , pentru  $n \in \mathbb{N}$ , având deci distribuția:

$$X : \left( \frac{\lambda^n}{n!} e^{-\lambda} \right)_{n \in \mathbb{N}}.$$

Notăm  $X \in \text{Poiss}(\lambda)$ .

**Exemplul 2.4.4.** *Variabile aleatoare geometrice.*

O variabilă aleatoare geometrică  $X$  de parametru  $p$  ia valoarea  $n$  cu probabilitatea  $p q^{n-1}$ , pentru  $n \in \mathbb{N}^*$ , unde  $q = 1 - p$ .  $X$  are distribuția:

$$X : \left( p q^{n-1} \right)_{n \in \mathbb{N}^*}.$$

Notăm  $X \in \text{Geom}(p)$ . Variabila  $X$  indică numărul de experiențe, independente, identice, necesar realizării (aparitiei) unui eveniment care are probabilitatea  $p$  de realizare în cadrul fiecărei experiențe (schema geometrică).

## 2.5 Variabile aleatoare continue. Exemple clasice

Un tip important de variabile aleatoare sunt cele "continue".

**Definiția 2.5.1.** Fie  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmp de probabilitate și  $X : \Omega \rightarrow \mathbb{R}$  o variabilă aleatoare.  $X$  se numește variabilă aleatoare continuă dacă există o funcție continuă  $f : \mathbb{R} \rightarrow [0, \infty)$  cu proprietatea

$$F(x) = \int_{-\infty}^x f(t) dt, \quad \forall x \in \mathbb{R}.$$

Funcția  $f$  se numește densitatea de probabilitate a variabilei aleatoare  $X$  (sau funcția de densitate a v.a.  $X$ ).

Proprietățile densității unei variabile aleatoare reale sunt evidențiate în propoziția de mai jos.

**Propoziția 2.5.1.** Fie  $f : \mathbb{R} \rightarrow [0, \infty)$  funcția de densitate asociată unei variabile aleatoare de tip continuu  $X : \Omega \rightarrow \mathbb{R}$ . Notăm  $F : \mathbb{R} \rightarrow [0, 1]$  funcția sa de repartiție. Atunci:

1.  $F$  este de clasă  $\mathcal{C}^1$  pe  $\mathbb{R}$ , cu  $F'(x) = f(x)$ ,  $\forall x \in \mathbb{R}$ ;
2.  $\int_{\mathbb{R}} f(t) dt = 1$ ;
3.  $\mathbb{P}\{X = x\} = 0$ ,  $\forall x \in \mathbb{R}$ ;
4.  $\mathbb{P}\{a \leq X \leq b\} = \int_a^b f(t) dt$ ,  $\forall [a, b] \subset \mathbb{R}$ .

*Demonstrație.*

1. Conform definiției,  $F$  este o primitivă a lui  $f$  pe  $\mathbb{R}$ .
2.  $\int_{\mathbb{R}} f(t) dt = \lim_{x \rightarrow \infty} \int_{-\infty}^x f(t) dt = \lim_{x \rightarrow \infty} F(x) = 1$ .
3.  $F$  este continuă pe  $\mathbb{R}$ , deci  $\mathbb{P}\{X = x\} = F(x) - F(x-0) = 0$ ,  $\forall x \in \mathbb{R}$ .
4.  $\mathbb{P}\{a \leq X \leq b\} = \mathbb{P}\{X \leq b\} - \mathbb{P}\{X < a\} = \mathbb{P}\{X \leq b\} - \mathbb{P}\{X \leq a\} = F(b) - F(a) = \int_a^b f(t) dt$ ,  $\forall [a, b] \subset \mathbb{R}$ .  $\square$

Fie variabilele aleatoare continue, independente,  $X$  și  $Y$ , cu densitățile  $f, g : \mathbb{R} \rightarrow [0, 1]$ . Din Propoziția 2.3.2 se deduce că variabila aleatoare  $X + Y$  are densitatea  $f * g$ , unde

$$f * g : \mathbb{R} \rightarrow [0, \infty), \quad (f * g)(x) = \int_{\mathbb{R}} f(x-t)g(t) dt, \quad \forall x \in \mathbb{R},$$

este convoluția densităților  $f$  și  $g$ .

Vom prezenta în continuare câteva exemple clasice de repartiții continue.

**Exemplul 2.5.1.** Distribuția normală.

Este cel mai important exemplu de distribuție de tip continuu. Astfel, spunem că o variabilă aleatoare reală  $X$  are o repartiție normală (gaussiană) de parametrii 0 și 1 dacă are funcția de densitate:

$$\varphi(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}, \quad \forall t \in \mathbb{R}.$$

Variabila normală (standard)  $X$  admite funcție de repartiție:

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt, \quad \forall x \in \mathbb{R}.$$

Notăm  $X \in N(0, 1)$ . Distribuția normală standard este *legea limită universală*, conform *Teoremei limită centrală*.

Generalizare.  $X \in N(\mu, \sigma^2)$ , unde  $\mu \in \mathbb{R}$ ,  $\sigma > 0$ , dacă admite densitatea de probabilitate

$$\varphi(t) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(t-\mu)^2}{2\sigma^2}}, \quad \forall t \in \mathbb{R}.$$

**Exemplul 2.5.2.** *Distribuția exponențială.*

Variabila aleatoare  $X$  are o distribuție exponențială de parametru  $\lambda > 0$ , notat prin  $X \in \text{Exp}(\lambda)$ , dacă ia valori în intervalul  $[0, \infty)$  (deci este o *variabilă aleatoare pozitivă*) și admite funcția de repartiție

$$F(x) = 1 - e^{-\lambda x}, \quad \forall x \geq 0.$$

Distribuția exponențială este fundamentală în teoria fiabilității, caracterizând modelele de tip Markov.

**Exemplul 2.5.3.** *Distribuția Gama.*

Variabila aleatoare  $X$  are o distribuție Gama de parametri  $\alpha, \beta > 0$ , notat prin  $X \in \text{Gama}(\alpha, \beta)$ , dacă ia valori în intervalul  $(0, \infty)$  și admite funcția de densitate

$$f(x) = \frac{x^{\alpha-1} e^{-\frac{x}{\beta}}}{\beta^\alpha \Gamma(\alpha)}, \quad \forall x > 0,$$

unde

$$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$$

este funcția lui Euler de prima speță.

În statistică, distribuția de tip  $\text{Gam}(n/2, 2)$ , cu  $n \in \mathbb{N}^*$ , notată prin  $\chi_n^2$ , are o importanță majoră.

**Exemplul 2.5.4.** *Distribuția Beta.*

Variabila aleatoare  $X$  are o distribuție Beta de parametri  $\alpha, \beta > 0$ , notat prin  $X \in \text{Beta}(\alpha, \beta)$ , dacă ia valori în intervalul  $(0, 1)$  și admite funcția de densitate

$$f(x) = \frac{x^{\alpha-1} (1-x)^{\beta-1}}{B(\alpha, \beta)}, \quad \forall x \in (0, 1),$$

unde

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$$

este funcția lui Euler de a doua speță.

## 2.6 Media. Medii de ordin superior

Pentru o variabilă aleatoare reală, media și dispersia reprezintă cele mai importante caracteristici numerice. Astfel, media unei variabile aleatoare (dacă există) indicăcea mai așteptată valoare a variabilei aleatoare.

**Definiția 2.6.1.** Fie  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmp de probabilitate și  $X : \Omega \rightarrow \mathbb{R}$  o variabilă aleatoare având funcția de repartiție  $F : \mathbb{R} \rightarrow [0, 1]$ . Mărima:

$$\mathbb{E}(X) := \int_{-\infty}^{\infty} x dF(x)$$

se numește media lui  $X$ . Media este definită în ipoteza că integrala de tip Stieltjes-Riemann de mai sus este convergentă.

Calculul mediei se explicitează astfel:

1. pentru o variabilă aleatoare  $X$  de tip discret, care ia valorile  $x_i$  cu probabilitățile  $p_i$ , pentru  $i \in I$ , media devine

$$\mathbb{E}(X) = \sum_{i \in I} x_i p_i;$$

2. pentru o variabilă aleatoare  $X$  de tip continuu, care admite densitatea de probabilitate  $f : \mathbb{R} \rightarrow [0, \infty)$ , media devine

$$\mathbb{E}(X) := \int_{-\infty}^{\infty} x f(x) dx.$$

Următoarea propoziție stabilește proprietăți de bază ale mediei variabilelor aleatoare.

**Propoziția 2.6.1.** Fie  $X$  și  $Y$  două variabile aleatoare cu medie finită.

1.  $\mathbb{E}(aX) = a\mathbb{E}(X)$ ,  $\forall a \in \mathbb{R}$ ;
2.  $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$ ;
3. dacă  $X$  și  $Y$  sunt independente, atunci  $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$ .

*Demonstrație.* Vom trata doar cazul discret. Presupunem că  $X$  și  $Y$  au distribuțiile

$$X : \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}, \quad Y : \begin{pmatrix} y_j \\ p'_j \end{pmatrix}_{j \in J},$$

unde  $I$  și  $J$  sunt mulțimi de indici cel mult numărabile.

1. Pentru  $a \in \mathbb{R}$ , avem:

$$\mathbb{E}(aX) = \sum_{i \in I} (ax_i) p_i = a \sum_{i \in I} x_i p_i = a\mathbb{E}(X).$$

2. Fie  $A_{ij} = \{X = x_i, Y = y_j\}$  și  $p_{ij} = \mathbb{P}(A_{ij})$ ,  $(i, j) \in I \times J$ . Atunci

$$\sum_{j \in J} p_{ij} = \sum_{j \in J} \mathbb{P}(A_{ij}) = \mathbb{P}(\cup_{j \in J} A_{ij}) = \mathbb{P}\{X = x_i\} = p_i, \quad \forall i \in I,$$

respectiv

$$\sum_{i \in I} p_{ij} = \sum_{i \in I} \mathbb{P}(A_{ij}) = \mathbb{P}(\cup_{i \in I} A_{ij}) = \mathbb{P}\{Y = y_j\} = p'_j, \quad \forall j \in J.$$

Deoarece  $X + Y$  are distribuția

$$X + Y : \left( \begin{array}{c} x_i + y_j \\ p_{ij} \end{array} \right)_{(i,j) \in I \times J},$$

obținem

$$\begin{aligned} \mathbb{E}(X + Y) &= \sum_{(i,j) \in I \times J} (x_i + y_j) p_{ij} = \sum_{i \in I} \left( x_i \sum_{j \in J} p_{ij} \right) + \sum_{j \in J} \left( y_j \sum_{i \in I} p_{ij} \right) \\ &= \sum_{i \in I} (x_i p_i) + \sum_{j \in J} (y_j p'_j) = \mathbb{E}(X) + \mathbb{E}(Y). \end{aligned}$$

3. Dacă  $X$  și  $Y$  sunt independente, atunci  $p_{ij} = p_i p'_j$ ,  $\forall (i, j) \in I \times J$ . Rezultă

$$\begin{aligned} \mathbb{E}(XY) &= \sum_{(i,j) \in I \times J} (x_i y_j) p_{ij} = \sum_{(i,j) \in I \times J} (x_i p_i) (y_j p'_j) \\ &= \sum_{i \in I} (x_i p_i) \sum_{j \in J} (y_j p'_j) = \mathbb{E}(X) \mathbb{E}(Y). \end{aligned}$$

Astfel, proprietățile mediei sunt demonstrate în cazul discret.  $\square$

Fie  $X : \Omega \rightarrow \mathbb{R}$  o variabilă aleatoare iar  $\varphi : \mathbb{R} \rightarrow \mathbb{R}$  o funcție reală măsurabilă (în particular,  $\varphi$  continuă). Funcția compusă  $\varphi(X) := \varphi \circ X : \Omega \rightarrow \mathbb{R}$  este de asemenea o variabilă aleatoare definită pe  $\Omega$ . Dacă  $X$  admite funcția de repartiție  $F$ , atunci

$$\mathbb{E}(\varphi(X)) = \int_{-\infty}^{\infty} \varphi(x) dF(x),$$

în ipoteza că integrala este convergentă. În particular, în cazul când  $\varphi$  este o funcție putere sau modului unei funcții putere, obținem mediile de ordin superior, respectiv mediile absolute de ordin superior.

**Definiția 2.6.2.** Fie  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmp de probabilitate și  $X : \Omega \rightarrow \mathbb{R}$  o variabilă aleatoare.

1. Media de ordin  $k \in \mathbb{N}^*$  a variabilei aleatoare  $X$  se definește prin

$$\mathbb{E}(X^k) = \int_{-\infty}^{\infty} x^k dx,$$

dacă integrala este convergentă.

2. Media absolută de ordin  $k \in \mathbb{N}^*$  a variabilei aleatoare  $X$  se definește prin

$$\mathbb{E}(|X|^k) = \int_{-\infty}^{\infty} |x|^k dx,$$

dacă integrala este convergentă. Notăm  $L^k = L^k(\Omega)$  mulțimea variabilelor aleatoare (definite pe  $\Omega$ ) cu medie absolută finită de ordinul  $k$ .

Menționăm că  $L^k(\Omega)$  este un spațiu vectorial normat. Din inegalitatea lui Hölder se deduc incluziunile

$$L^{k+1}(\Omega) \subset L^k(\Omega), \quad k \in \mathbb{N}^*.$$

În plus, dacă  $X \in L^k(\Omega)$ , atunci  $X$  are medie finită de ordinele  $i = 1, \dots, n$ .

**Exemplul 2.6.1.** *Mediile unor distribuții clasice.*

1. Distribuția Bernoulli:  $X \in \text{Bin}(1, p) \Rightarrow \mathbb{E}(X) = p$ .
2. Distribuția binomială:  $X \in \text{Bin}(n, p) \Rightarrow \mathbb{E}(X) = np$ .
3. Distribuția Poisson:  $X \in \text{Poiiss}(\lambda) \Rightarrow \mathbb{E}(X) = \lambda$ .
4. Distribuția geometrică:  $X \in \text{Geom}(p) \Rightarrow \mathbb{E}(X) = 1/p$ .
5. Distribuția normală:  $X \in N(\mu, \sigma^2) \Rightarrow \mathbb{E}(X) = \mu$ .
6. Distribuția exponențială:  $X \in \text{Exp}(\lambda) \Rightarrow \mathbb{E}(X) = 1/\lambda$ .

## 2.7 Dispersia

Dispersia unei variabile aleatoare (din spațiul  $L^2$ ) este un indicator al gradului de împrăștiere a valorilor sale în jurul mediei.

**Definiția 2.7.1.** Fie  $X \in L^2(\Omega)$ , cu  $\mathbb{E}(X) = \mu$ . Mărima:

$$V(X) = \int_{-\infty}^{\infty} (x - \mu)^2 dF(x) = \mathbb{E}[(X - \mathbb{E}(X))^2]$$

se numește dispersia lui  $X$ . Mărima

$$\sigma(X) = \sqrt{V(X)}$$

se numește abaterea medie pătratică a variabilei aleatoare  $X$ .

Dispersia are următoarele proprietăți elementare.

**Propoziția 2.7.1.** Fie  $X, Y \in L^2(\Omega)$ .

1.  $V(X) \geq 0$ ;
2.  $V(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$  (formula de calcul a dispersiei);
3.  $V(aX) = a^2V(X)$ ,  $\forall a \in \mathbb{R}$ ;
4. dacă  $X$  și  $Y$  sunt v.a. independente, atunci  $V(X + Y) = V(X) + V(Y)$ .



*Demonstrație.* Proprietățile 1 și 3 sunt evidente. Fie  $\mu = \mathbb{E}(X)$  și  $\eta = \mathbb{E}(Y)$ . Formula de calcul a dispersiei se obține astfel:

$$V(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}(X^2 - 2\mu X + \mu^2) = \mathbb{E}(X^2) - 2\mu\mathbb{E}(X) + \mu^2 = \mathbb{E}(X^2) - \mu^2.$$

Conform Propoziției 2.6.1 și formulei demonstrate avem:

$$\begin{aligned} V(X + Y) &= \mathbb{E}[(X + Y)^2] - [\mathbb{E}(X + Y)]^2 = \mathbb{E}(X^2 + 2XY + Y^2) - (\mu + \eta)^2 \\ &= \mathbb{E}(X^2) + \mathbb{E}(Y^2) + 2\mu\eta - \mu^2 - 2\mu\eta - \eta^2 = [\mathbb{E}(X^2) - \mu^2] + [\mathbb{E}(Y^2) - \eta^2] = V(X) + V(Y). \end{aligned}$$

□

**Exemplul 2.7.1.** *Dispersiile unor distribuții clasice.*

1. Distribuția Bernoulli:  $X \in \text{Bin}(1, p) \Rightarrow V(X) = pq.$
2. Distribuția binomială:  $X \in \text{Bin}(n, p) \Rightarrow V(X) = npq.$
3. Distribuția Poisson:  $X \in \text{Poiss}(\lambda) \Rightarrow V(X) = \lambda.$
4. Distribuția geometrică:  $X \in \text{Geom}(p) \Rightarrow V(X) = q/p^2.$
5. Distribuția normală:  $X \in N(\mu, \sigma^2) \Rightarrow V(X) = \sigma^2.$

## 2.8 Corelația

Corelația a două variabile aleatoare este un indicator al tipului de dependență al acestora.

**Definiția 2.8.1.** Fie  $X, Y \in L^2(\Omega)$ . Corelația variabilelor aleatoare  $X$  și  $Y$  se definește prin:

$$\lambda(X, Y) = \mathbb{E}\{[X - \mathbb{E}(X)][Y - \mathbb{E}(Y)]\}.$$

*Mărimea*

$$\rho(X, Y) = \frac{\lambda(X, Y)}{\sigma(X)\sigma(Y)}$$

se numește coeficientul de corelație al variabilelor aleatoare  $X$  și  $Y$ .

Propoziția următoare stabilește formula de calcul a corelației și o proprietate a coeficientului de corelație.

**Propoziția 2.8.1.** *Cu notațiile anterioare, avem:*

1.  $\lambda(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y);$
2. dacă  $X$  și  $Y$  sunt independente, atunci  $\lambda(X, Y) = 0;$
3.  $\rho(X, Y) \in [-1, 1].$

*Demonstrație.*

1. Avem

$$\lambda(X, Y) = \mathbb{E}(XY - \mu Y - \eta X + \mu\eta) = \mathbb{E}(XY) - \mu\mathbb{E}(Y) - \eta\mathbb{E}(X) + \mu\eta = \mathbb{E}(XY) - \mu\eta.$$

2. Din inegalitatea

$$\mathbb{E} \{ [t(X - \mu) + (Y - \eta)]^2 \} \geq 0, \quad \forall t \in \mathbb{R},$$

sau

$$V(X)t^2 + 2\lambda(X, Y)t + V(Y) \geq 0, \quad \forall t \in \mathbb{R},$$

obținem

$$\Delta := 4(\lambda^2(X, Y) - V(X)V(Y)) \leq 0.$$

Rezultă  $|\rho(X, Y)| \leq 1$ .  $\square$

## 2.9 Funcția caracteristică

Funcția caracteristică asociată unei variabile aleatoare reprezintă un instrument matematic important. Pentru variabilele aleatoare de tip continuu, funcția caracteristică reprezintă transformata Fourier a funcției de densitate. Transformarea integrală Fourier este importantă în *calculul operațional*.

**Definiția 2.9.1.** Fie  $X$  o variabilă aleatoare având funcția de repartiție  $F$ . Funcția  $\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$ , definită prin

$$\varphi_X(t) = \mathbb{E}(e^{itX}) = \int_{-\infty}^{\infty} e^{itx} dF(x), \quad t \in \mathbb{R},$$

se numește funcția caracteristică a variabilei aleatoare  $X$ .

Fie  $X$  o variabilă aleatoare de tip continuu, cu densitatea de probabilitate  $f$ . În acest caz, funcția sa caracteristică se reprezintă astfel

$$\varphi_X(t) = \int_{-\infty}^{\infty} e^{itx} f(x) dx, \quad t \in \mathbb{R},$$

adică  $\varphi_X$  reprezintă transformata Fourier a funcției  $f$ .

Dacă  $X$  este o variabilă aleatoare discretă, cu distribuția

$$X : \left( \begin{array}{c} x_k \\ p_k \end{array} \right)_{k \in I},$$

atunci funcția sa caracteristică se calculează astfel

$$\varphi_X(t) = \sum_{k \in I} e^{itx_k} p_k.$$

Prezentăm în continuare principalele proprietăți ale funcției caracteristice.

**Teorema 2.9.1.** Fie  $X$  o variabilă aleatoare având funcția de repartiție  $F$  și funcția caracteristică  $\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$ . Au loc următoarele proprietăți:

1.  $\varphi_X(0) = 1$ ;
2.  $\varphi(-t) = \overline{\varphi_X(t)}$ ,  $\forall t \in \mathbb{R}$ ;
3.  $|\varphi_X(t)| \leq 1$ ,  $\forall t \in \mathbb{R}$ ;
4.  $\varphi_{aX+b}(t) = e^{ibt} \varphi_X(at)$ ,  $\forall t \in \mathbb{R}$ ,  $\forall a, b \in \mathbb{R}$ ;
5.  $\varphi_X$  este uniform continuă (deci și continuă) pe  $\mathbb{R}$ ;
6. dacă  $X \in L^n(\Omega)$ , atunci  $\varphi_X$  este derivabilă de ordinul  $n$ , cu

$$\varphi_X^{(n)}(t) = i^n \int_{-\infty}^{\infty} x^n e^{itx} dF(x), \quad t \in \mathbb{R};$$

7. dacă  $X \in \cap_{n=1}^{\infty} L^n(\Omega)$ , atunci  $\varphi_X$  este dezvoltabilă în serie Taylor în jurul originii:

$$\varphi_X(t) = \sum_{n=0}^{\infty} \frac{t^n}{n!} \varphi_X^{(n)}(0),$$

$$\text{cu } \varphi_X^{(n)}(0) = i^n \mathbb{E}(X^n), \quad n \in \mathbb{N}.$$

*Demonstrație.*

1.  $\varphi_X(0) = \mathbb{E}(e^0) = \mathbb{E}(1) = 1$ .
2.  $\varphi_X(-t) = \mathbb{E}(e^{-itX}) = \mathbb{E}(\overline{e^{itX}}) = \overline{\varphi_X(t)}$ ,  $\forall t \in \mathbb{R}$ .
3.  $|\varphi_X(t)| = \left| \int_{-\infty}^{\infty} e^{itx} dF(x) \right| \leq \int_{-\infty}^{\infty} |e^{itx}| dF(x) = \int_{-\infty}^{\infty} 1 dF(x) = 1$ ,  $\forall t \in \mathbb{R}$ .
4. Fie  $a, b \in \mathbb{R}$ .  $\varphi_{aX+b}(t) = \int_{-\infty}^{\infty} e^{it(ax+b)} dF(x) = e^{ibt} \int_{-\infty}^{\infty} e^{i(at)x} dF(x) = e^{ibt} \varphi_X(at)$ .
5. Fie  $t \in \mathbb{R}$  și  $h > 0$ . Avem

$$\begin{aligned} |\varphi_X(t+h) - \varphi_X(t)| &= \left| \int_{-\infty}^{\infty} e^{itx} (e^{ihx} - 1) dF(x) \right| \\ &\leq \int_{-\infty}^{\infty} |e^{itx}| |e^{ihx} - 1| dF(x) = 2 \int_{-\infty}^{\infty} \left| \sin \frac{hx}{2} \right| dF(x). \end{aligned}$$

Fie  $\varepsilon > 0$ . Cum  $\int_{-\infty}^{\infty} \left| \sin \frac{hx}{2} \right| dF(x) \leq \int_{-\infty}^{\infty} dF(x) = 1$ , deducem că există  $a > 0$  astfel ca

$$\int_{(-\infty, -a] \cup [a, \infty)} \left| \sin \frac{hx}{2} \right| dF(x) < \varepsilon/4.$$

Apoi, pentru  $h < \varepsilon/2a$ , avem

$$2 \int_{[-a, a]} \left| \sin \frac{hx}{2} \right| dF(x) \leq \int_{[-a, a]} h |x| dF(x) \leq ha \int_{-a}^a dF(x) \leq ha < \varepsilon/2.$$

Rezultă

$$|\varphi_X(t+h) - \varphi_X(t)| < \varepsilon, \quad \forall h \in \left(0, \frac{\varepsilon}{2a}\right).$$

Ca urmare,  $\varphi_X$  este uniform continuă pe  $\mathbb{R}$ .

6. Se aplică teorema de derivare a integralelor improprii cu parametru.

7. Conform formulei anterioare, avem

$$\varphi_X^{(n)}(0) = i^n \int_{-\infty}^{\infty} x^n e^0 dF(x) = i^n \mathbb{E}(X^n).$$

Atunci, dezvoltând în serie Taylor exponențială, obținem

$$\varphi_X(t) = \int_{-\infty}^{\infty} e^{itx} dF(x) = \int_{-\infty}^{\infty} \sum_{n=0}^{\infty} \frac{(itx)^n}{n!} dF(x) = \sum_{n=0}^{\infty} \frac{t^n}{n!} [i^n \mathbb{E}(X^n)] = \sum_{n=0}^{\infty} \frac{t^n}{n!} \varphi_X^{(n)}(0),$$

pentru oricare  $t \in \mathbb{R}$ .  $\square$

**Teorema 2.9.2.** (Teorema multiplicării) Dacă  $X_1, X_2, \dots, X_n$  sunt variabile aleatoare independente, atunci

$$\varphi_{X_1+X_2+\dots+X_n} = \varphi_{X_1} \varphi_{X_2} \dots \varphi_{X_n}.$$

*Demonstrație.* Media produsului unui număr finit de variabile aleatoare independente este egală cu produsul mediilor acestor variabile aleatoare. Atunci

$$\varphi_{\sum_{k=1}^n X_k}(t) = \mathbb{E} \left( e^{it \sum_{k=1}^n X_k} \right) = \mathbb{E} \left( \prod_{k=1}^n e^{itX_k} \right) = \prod_{k=1}^n \mathbb{E} (e^{itX_k}) = \prod_{k=1}^n \varphi_{X_k}(t), \quad t \in \mathbb{R}. \quad \square$$

**Teorema 2.9.3.** (Teorema de unicitate) Fie  $X$  o variabilă aleatoare cu funcția de repartiție  $F$  și funcția caracteristică  $\varphi_X$ . Atunci

1.

$$F(x_2) - F(x_1) = \mathbb{P}\{x_1 < X \leq x_2\} = \frac{1}{\pi} \lim_{c \rightarrow \infty} \int_{-c}^c \frac{e^{-itx_1} - e^{-itx_2}}{it} \varphi_X(t) dt, \quad \forall x_1 < x_2;$$

2.

$$F(x) = \frac{1}{2\pi} \lim_{y \rightarrow -\infty} \lim_{c \rightarrow \infty} \int_{-c}^c \frac{e^{-ity} - e^{-itx}}{it} \varphi_X(t) dt, \quad \forall x \in \mathbb{R}.$$

*Demonstrație.* Se aplică transformarea Fourier inversă.  $\square$

**Exemplul 2.9.1.** Funcțiile caracteristice ale unor distribuții clasice.

1. Distribuția Bernoulli:  $X \in \text{Bin}(1, p) \Rightarrow \varphi_X(t) = 1 + p(e^{it} - 1), \quad t \in \mathbb{R}.$

2. Distribuția binomială:  $X \in \text{Bin}(n, p) \Rightarrow \varphi_X(t) = [1 + p(e^{it} - 1)]^n, \quad t \in \mathbb{R}.$

3. Distribuția Poisson:  $X \in \text{Pois}(\lambda) \Rightarrow \varphi_X(t) = e^{\lambda(e^{it} - 1)}, \quad t \in \mathbb{R}.$

4. Distribuția geometrică:  $X \in \text{Geom}(p) \Rightarrow \varphi_X(t) = \frac{pe^{it}}{pe^{it} - e^{it} + 1}, \quad t \in \mathbb{R}.$

5. Distribuția normală:  $X \in N(\mu, \sigma^2) \Rightarrow \varphi_X(t) = e^{i\mu t - \frac{t^2 \sigma^2}{2}}, \quad t \in \mathbb{R}.$

6. Distribuția exponențială:  $X \in \text{Exp}(\lambda) \Rightarrow \varphi_X(t) = \frac{\lambda}{\lambda - it}, \quad t \in \mathbb{R}.$

## 2.10 Rezumat

Variabilele aleatoare se interpretează ca o "enumerare" a rezultatelor (măsurabile) potențiale ale unui anumit experiment. Fiecare din aceste rezultate posibile are o probabilitate de realizare.

Fie  $(\Omega, \mathcal{F}, \mathbb{P})$  un câmp de probabilitate. O funcție măsurabilă reală  $X : \Omega \rightarrow \mathbb{R}$  se numește *variabilă aleatoare*. Conform definiției,  $\{X \in I\} \in \mathcal{F}$  pentru orice interval real  $I$ . În particular,  $\{X \in (-\infty, a]\} = \{X \leq a\} \in \mathcal{F}$ ,  $\forall a \in \mathbb{R}$ .

O funcție  $X : \Omega \rightarrow \mathbb{R}^d$ ,  $(\mathcal{F}, \mathcal{B}_{\mathbb{R}^d})$  măsurabilă, se numește *vector aleator*. Fie  $X_i$ ,  $i = 1, 2, \dots, d$ , componentele scalare ale funcției  $X$ , deci  $X = (X_1, X_2, \dots, X_d)$ . Atunci

$$\{X_1 \leq a_1, X_2 \leq a_2, \dots, X_d \leq a_d\} \in \mathcal{F}, \forall (a_1, a_2, \dots, a_d) \in \mathbb{R}^d.$$

Fie  $X : \Omega \rightarrow \mathbb{R}$  o variabilă aleatoare. Funcția reală  $F : \mathbb{R} \rightarrow [0, 1]$ , definită prin

$$F(x) = \mathbb{P}\{X \leq x\} = \mathbb{P}(\{\omega \in \Omega | X(\omega) \leq x\}), \quad x \in \mathbb{R},$$

se numește *funcția de repartiție* a variabilei aleatoare  $X$ .

Funcția de repartiție are următoarele proprietăți:

1.  $F$  este monoton crescătoare pe  $\mathbb{R}$ ;
2.  $F$  este continuă la dreapta pe mulțimea  $\mathbb{R}$  ( $F(x+0) := \lim_{t \downarrow x} F(t) = F(x)$ ,  $\forall x \in \mathbb{R}$ );
3.  $\lim_{x \rightarrow -\infty} F(x) = 0$ ;  $\lim_{x \rightarrow \infty} F(x) = 1$ ;
4.  $F(x-0) := \lim_{t \uparrow x} F(t) = \mathbb{P}\{X < x\}$ ,  $\forall x \in \mathbb{R}$ ;
5.  $\mathbb{P}\{X = x\} = F(x) - F(x-0)$ ,  $\forall x \in \mathbb{R}$ ;
6.  $\mathbb{P}\{a < X \leq b\} = F(b) - F(a)$ ,  $\forall a, b \in \mathbb{R}$ , cu  $a < b$ ;
7.  $\mathbb{P}\{X > x\} = 1 - F(x)$ ,  $\forall x \in \mathbb{R}$ .

Variabilele aleatoare  $X_i$ ,  $i \in I$ , se numesc independente dacă, pentru oricare oricare indici distincți  $i_1, i_2, \dots, i_n$  din mulțimea  $I$  și oricare  $A_1, A_2, \dots, A_n \in \mathcal{B}_{\mathbb{R}}$  are loc

$$\mathbb{P}\{X_{i_1} \in A_1, X_{i_2} \in A_2, \dots, X_{i_n} \in A_n\} = \mathbb{P}\{X_{i_1} \in A_1\} \mathbb{P}\{X_{i_2} \in A_2\} \dots \mathbb{P}\{X_{i_n} \in A_n\}.$$

$X$  se numește variabilă aleatoare discretă dacă mulțimea  $X(\Omega)$  este cel mult numărabilă. Fie  $X(\Omega) = \{x_i, i \in I\} \subset \mathbb{R}$ , unde  $I$  este o mulțime de indici cel mult numărabilă. Notăm  $p_i = \mathbb{P}\{X = x_i\}$ ,  $i \in I$ . Avem  $p_i \geq 0$ ,  $\forall i \in I$  și  $\sum_{i \in I} p_i = 1$ . Distribuția variabilei aleatoare  $X$  se reprezintă prin:

$$X : \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}.$$

Variabila aleatoare  $X$  se numește *de tip continuu* dacă există o funcție continuă  $f : \mathbb{R} \rightarrow [0, \infty)$  cu proprietatea

$$F(x) = \int_{-\infty}^x f(t) dt, \quad \forall x \in \mathbb{R}.$$

Funcția  $f$  se numește *densitatea de probabilitate* a variabilei aleatoare  $X$  (sau *funcția de densitate* a v.a.  $X$ ).

Densitatea de probabilitate are proprietățile:

1.  $F$  este de clasă  $\mathcal{C}^1$  pe  $\mathbb{R}$ , cu  $F'(x) = f(x)$ ,  $\forall x \in \mathbb{R}$ ;
2.  $\int_{\mathbb{R}} f(t) dt = 1$ ;
3.  $\mathbb{P}\{X = x\} = 0$ ,  $\forall x \in \mathbb{R}$ ;
4.  $\mathbb{P}\{a \leq X \leq b\} = \int_a^b f(t) dt$ ,  $\forall [a, b] \subset \mathbb{R}$ .

Fie  $X : \Omega \rightarrow \mathbb{R}$  o variabilă aleatoare având funcția de repartiție  $F : \mathbb{R} \rightarrow [0, 1]$ . Mărima:

$$\mathbb{E}(X) := \int_{-\infty}^{\infty} x dF(x)$$

se numește *media* lui  $X$ . Media este definită în ipoteza că integrala de tip Stieltjes-Riemann de mai sus este convergentă.

Calculul mediei:

1. pentru o variabilă aleatoare  $X$  de tip discret, care ia valorile  $x_i$  cu probabilitățile  $p_i$ , pentru  $i \in I$ :

$$\mathbb{E}(X) = \sum_{i \in I} x_i p_i;$$

2. pentru o variabilă aleatoare  $X$  de tip continuu, care admite densitatea de probabilitate  $f : \mathbb{R} \rightarrow [0, \infty)$ :

$$\mathbb{E}(X) := \int_{-\infty}^{\infty} x f(x) dx.$$

Media are următoarele proprietăți:

1.  $\mathbb{E}(aX) = a\mathbb{E}(X)$ ,  $\forall a \in \mathbb{R}$ ;
2.  $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$ ;
3. dacă  $X$  și  $Y$  sunt independente, atunci  $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$ .

Dacă  $X$  admite funcția de repartiție  $F$ , iar  $\varphi$  este o funcție reală măsurabilă, atunci

$$\mathbb{E}(\varphi(X)) = \int_{-\infty}^{\infty} \varphi(x) dF(x),$$

în ipoteza că integrala este convergentă.

Definim:

1. *media de ordin*  $k \in \mathbb{N}^*$  a variabilei aleatoare  $X$ :

$$\mathbb{E}(X^k) = \int_{-\infty}^{\infty} x^k dx,$$

dacă integrala este convergentă.

2. *media absolută de ordin*  $k \in \mathbb{N}^*$  a variabilei aleatoare  $X$ :

$$\mathbb{E}(|X|^k) = \int_{-\infty}^{\infty} |x|^k dx,$$

dacă integrala este convergentă. Notăm  $L^k = L^k(\Omega)$  mulțimea variabilelor aleatoare (definite pe  $\Omega$ ) cu medie absolută finită de ordinul  $k$ .

- Mărimea:

$$V(X) = \int_{-\infty}^{\infty} (x - \mu)^2 dF(x) = \mathbb{E}(X - \mathbb{E}(X))^2 = \mathbb{E}(X^2) - \mathbb{E}^2(X)$$

se numește *dispersia* lui  $X$ .

- Mărimea

$$\sigma(X) = \sqrt{V(X)}$$

se numește *abaterea medie pătratică* a variabilei aleatoare  $X$ .

Dispersia are următoarele proprietăți:

1.  $V(X) \geq 0$ ;
2.  $V(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$  (formula de calcul a dispersiei);
3.  $V(aX) = a^2V(X)$ ,  $\forall a \in \mathbb{R}$ ;
4. dacă  $X$  și  $Y$  sunt v.a. independente, atunci  $V(X + Y) = V(X) + V(Y)$ .

Corelația a două variabile aleatoare este un indicator al tipului de dependență al acestora. Astfel, *corelația* variabilelor aleatoare  $X$  și  $Y$  se definește prin:

$$\lambda(X, Y) = \mathbb{E}\{[X - \mathbb{E}(X)][Y - \mathbb{E}(Y)]\}.$$

Mărimea

$$\rho(X, Y) = \frac{\lambda(X, Y)}{\sigma(X)\sigma(Y)}$$

se numește *coeficientul de corelație* al variabilelor aleatoare  $X$  și  $Y$ . Formula de calcul a corelației  $\lambda(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$ .

Dacă  $X$  și  $Y$  sunt v.a. independente, atunci  $\lambda(X, Y) = 0$ ;

Avem  $\rho(X, Y) \in [-1, 1]$ .

Fie  $X$  o variabilă aleatoare având funcția de repartiție  $F$ . Funcția  $\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$ , definită prin

$$\varphi_X(t) = \mathbb{E}(e^{itX}) = \int_{-\infty}^{\infty} e^{itx} dF(x), \quad t \in \mathbb{R},$$

se numește funcția caracteristică a variabilei aleatoare  $X$ .

Dacă  $X$  este o variabilă aleatoare de tip continuu, cu densitatea de probabilitate  $f$ , atunci

$$\varphi_X(t) = \int_{-\infty}^{\infty} e^{itx} f(x) dx, \quad t \in \mathbb{R}.$$

Dacă  $X$  este o variabilă aleatoare discretă, cu distribuția

$$X : \begin{pmatrix} x_k \\ p_k \end{pmatrix}_{k \in I},$$

atunci  $\varphi_X(t) = \sum_{k \in I} e^{itx_k} p_k$ .

## 2.11 Test

1. Definiți funcția de repartiție a unei variabile aleatoare și descrieți proprietățile acesteia. Discutați cazul variabilelor aleatoare independente.
2. Calculați media, dispersia și funcția caracteristică pentru o variabilă aleatoare:
  - (a) Poisson;
  - (b) exponențială;
  - (c) geometrică.
3. Variabila aleatoare  $X$  are distribuția discretă:

$$X : \begin{pmatrix} 1 & 2 & 3 \\ p_1 & p_2 & p_3 \end{pmatrix},$$

unde  $p_1, p_2, p_3 > 0$ , cu  $p_1 + p_2 + p_3 = 1$ . Știind că  $X$  are media  $E(X) = \frac{7}{4}$  și dispersia  $V(X) = \frac{11}{16}$ , să se determine probabilitățile  $p_1, p_2, p_3$ .

4. Să se determine constantele reale  $a$  și  $b$  astfel ca funcția  $F(x) = a + b \arctg x$ ,  $x \in \mathbb{R}$ , să fie funcția de repartiție a unei variabile aleatoare  $X$  și apoi să se calculeze  $E(X^2)$ .
5. Fie funcția  $f : \mathbb{R} \rightarrow \mathbb{R}$ ,

$$f(x) = \begin{cases} \frac{a}{\sqrt{1-x^2}}, & x \in (-1, 1) \\ 0, & x \in (-\infty, -1] \cup [1, \infty) \end{cases}.$$

- (a) Să se determine  $a > 0$  astfel încât  $f$  să reprezinte densitatea de probabilitate a unei variabile aleatoare  $X$ .
  - (b) Să se determine media  $E(X)$  și dispersia  $V(X)$  a variabilei aleatoare  $X$ .
  - (c) Să se calculeze  $\mathbb{P}\{|X| \leq \frac{1}{2}\}$ .
6. Timpul de așteptare într-o stație de autobuz este o variabilă aleatoare cu funcția de repartiție

$$F(x) = \begin{cases} 0, & x < 0; \\ x/2, & 0 \leq x < 1; \\ 1/2, & 1 \leq x < 2; \\ x/4, & 2 \leq x < 4; \\ 1, & x \geq 4. \end{cases}$$

Să se determine:

- (a) probabilitatea ca o persoană să aștepte în stație mai mult de 3 minute;
  - (b) probabilitatea ca o persoană să mai aștepte în stație cel puțin de 2 minute, după ce a așteptat 1 minut.
7. Să se calculeze funcția caracteristică a variabilei aleatoare  $X$  cu densitatea de probabilitate:

$$f(x) = \begin{cases} 0, & |x| \geq 2; \\ \frac{1}{2} \left(1 - \frac{|x|}{2}\right), & |x| < 2 \end{cases}.$$



# Capitolul 3

## Convergența șirurilor de variabile aleatoare

### 3.1 Introducere

Studiul convergența șirurilor de variabilelor aleatoare, în accepțiuni specifice teoriei probabilităților, evidențiază fenomene asimptotice utile. Un șir de variabile aleatoare poate converge la o variabilă aleatoare (distribuție limită) în sens "tare" sau în sens "slab". Convergența frecvenței de realizare a unui eveniment, într-un șir de experiențe identice și independente, la probabilitatea acelui eveniment este asigurată de *Legea numerelor mari*. Legea slabă a numerelor mari se deduce din inegalitatea lui Cebîșev. *Teorema limită centrală*, considerat cel mai important rezultat al teoriei probabilităților, stabilește convergența la legea normală a distribuției normalizate a sumelor parțiale ale unui șir de variabile aleatoare independente și identic distribuite. Rezultatele asimptotice menționate au o importanță majoră în *statistica matematică*.

### 3.2 Inegalități fundamentale în teoria probabilităților

Următoarele inegalități elementare joacă un rol fundamental în teoria probabilităților.

**Teorema 3.2.1.** (*Inegalitatea lui Markov*) Fie  $X \in L^n(\Omega)$ , unde  $n \in \mathbb{N}^*$ . Atunci

$$\mathbb{P}\{|X| > a\} \leq \frac{\mathbb{E}(|X|^n)}{a^n}, \quad \forall a > 0.$$

*Demonstrație.* Fie  $F$  funcția de repartiție a variabilei aleatoare  $X \in L^n(\Omega)$ . Pentru  $a > 0$ , avem

$$\begin{aligned} \mathbb{E}(|X|^n) &= \int_{[-a,a]} |x|^n dF(x) + \int_{(-\infty,-a] \cup [a,\infty)} |x|^n dF(x) \geq a^n \int_{(-\infty,-a] \cup [a,\infty)} 1 dF(x) \\ &= a^n [F(-a) + 1 - F(a)] \geq a^n \mathbb{P}\{|X| > a\}, \end{aligned}$$

de unde concluzia.  $\square$

**Teorema 3.2.2.** (Inegalitatea lui Cebîșev (Chebyshev)) Fie  $X \in L^2(\Omega)$ , având media  $\mathbb{E}(X) = \mu$  și dispersia  $V(X) = \sigma^2$ . Atunci

$$\mathbb{P}\{|X - \mu| > a\} \leq \frac{\sigma^2}{a^2}, \quad \forall a > 0.$$

*Demonstrație.* Aplicăm inegalitatea lui Markov variabilei aleatoare  $Z = X - \mu$ , pentru  $n = 2$ .  $\square$

Inegalitatea lui Cebîșev se utilizează la demonstrarea *legii slabe a numerelor mari*.

**Teorema 3.2.3.** (Inegalitatea lui Hölder) Fie  $p, q > 1$  astfel ca  $\frac{1}{p} + \frac{1}{q} = 1$ . Pentru două variabile aleatoare  $X$  și  $Y$  are loc inegalitatea

$$\mathbb{E}(|XY|) \leq [\mathbb{E}(|X|^p)]^{\frac{1}{p}} \cdot [\mathbb{E}(|Y|^q)]^{\frac{1}{q}}.$$

În particular, pentru  $Y = 1$ , avem

$$\mathbb{E}(|X|) \leq [\mathbb{E}(|X|^p)]^{\frac{1}{p}}, \quad \forall p > 1.$$

Pentru  $p = 2$ , obținem inegalitatea lui Cauchy-Buniakovski:

$$\mathbb{E}(|X|) \leq \sqrt{\mathbb{E}(X^2)}.$$

Inegalitatea de mai sus exprimă faptul că dispersia variabilei aleatoare  $X \in L^2(\Omega)$  este pozitivă. Astfel,

$$V(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2 \geq \mathbb{E}(X^2) - [\mathbb{E}(|X|)]^2 \geq 0.$$

**Teorema 3.2.4.** (Inegalitatea lui Lyapunov) Fie  $X$  o variabilă aleatoare și  $r, s \in \mathbb{N}^*$ , cu  $r < s$ . Are loc inegalitatea

$$[\mathbb{E}(|X|^r)]^{\frac{1}{r}} \leq [\mathbb{E}(|X|^s)]^{\frac{1}{s}}.$$

*Demonstrație.* Fie  $p = s/r > 1$  și  $q = p/(p-1) > 1$ . Avem  $\frac{1}{p} + \frac{1}{q} = 1$ . Atunci, conform inegalității lui Hölder, obținem

$$[\mathbb{E}(|X|^r)]^{\frac{1}{r}} \leq [\mathbb{E}(|X|^{pr})]^{\frac{1}{rp}} = [\mathbb{E}(|X|^s)]^{\frac{1}{s}}. \quad \square$$

**Consecință.**  $L^n(\Omega) \subset L^{n+1}(\Omega)$ ,  $\forall n \in \mathbb{N}^*$ .

### 3.3 Tipuri de convergență. Relații

Vom defini *convergența șirurilor de variabile aleatoare*, în diverse accepțiuni. Studiul comportării asimptotice a șirurilor de variabile aleatoare reprezintă o preocupare majoră a teoriei probabilităților.

**Definiția 3.3.1.** Fie  $X$  o variabilă aleatoare și  $(X_n)_{n \geq 1}$  un șir de variabile aleatoare definite pe câmpul de probabilitate  $(\Omega, \mathcal{F}, \mathbb{P})$ . Fie  $F$  funcția de repartiție a variabilei aleatoare  $X$ , iar  $F_n$  funcția de repartiție a variabilei aleatoare  $X_n$ ,  $n \geq 1$ . Definim următoarele tipuri de convergență ale șirului  $(X_n)_{n \geq 1}$  către limita  $X$ :

1. șirul  $(X_n)_{n \geq 1}$  converge în distribuție (repartiție) la  $X$ , notat prin

$$X_n \xrightarrow{d} X,$$

dacă  $\lim_{n \rightarrow \infty} F_n(x_0) = F(x_0)$ , pentru orice punct de continuitate  $x_0 \in \mathbb{R}$  al funcției  $F$ ;

2. șirul  $(X_n)_{n \geq 1}$  converge în probabilitate la  $X$ , notat prin

$$X_n \xrightarrow{p} X,$$

dacă  $\lim_{n \rightarrow \infty} \mathbb{P}\{|X_n - X| > \varepsilon\} = 0, \forall \varepsilon > 0$ ;

3. șirul  $(X_n)_{n \geq 1}$  converge aproape sigur la  $X$ , notat prin

$$X_n \xrightarrow{a.s.} X,$$

dacă  $\mathbb{P}\{X_n \rightarrow X\} = 1$ ;

4. șirul  $(X_n)_{n \geq 1}$  converge în spațiul  $L^k(\Omega)$  la  $X$ , unde  $k \in \mathbb{N}^*$ , notat prin

$$X_n \xrightarrow{L^k} X,$$

dacă  $\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|^k) = 0$ .

Convergențele ”în distribuție” și ”în probabilitate” sunt *convergențe slabe*, în timp ce convergențele ”aproape sigură” și ”în spațiul  $L^k(\Omega)$ ” sunt *convergențe tari*. Această clasificare formală este susținută de următoarea teoremă de ierarhizare a tipurilor de convergență definite anterior.

**Teorema 3.3.1.** Fie  $X$  o variabilă aleatoare și  $(X_n)_{n \geq 1}$  un șir de variabile aleatoare definite pe câmpul de probabilitate  $(\Omega, \mathcal{F}, \mathbb{P})$ . Au loc implicațiile

1.

$$X_n \xrightarrow{p} X \implies X_n \xrightarrow{d} X;$$

2.

$$X_n \xrightarrow{a.s.} X \implies X_n \xrightarrow{p} X;$$

3.

$$X_n \xrightarrow{L^k} X \implies X_n \xrightarrow{p} X.$$

Implicațiile reciproce sunt false.

*Demonstrație.*

1. Presupunem  $X_n \xrightarrow{p} X$ . Fie  $x_0 \in \mathbb{R}$  un punct de continuitate al funcției  $F$ . Considerăm  $\varepsilon > 0$ , arbitrar. Deoarece, pentru  $n \geq 1$ , avem

$$\{X \leq x_0 - \varepsilon\} \setminus \{|X_n - X| > \varepsilon\} \subset \{X \leq x_0 - \varepsilon\} \setminus \{X < X_n - \varepsilon\} \subset \{X_n \leq x_0\},$$

obținem

$$F(x_0 - \varepsilon) - \mathbb{P}\{|X_n - X| > \varepsilon\} \leq \mathbb{P}(\{X \leq x_0 - \varepsilon\} \setminus \{|X_n - X| > \varepsilon\}) \leq F_n(x_0).$$

Pe baza ipotezei,  $\lim_{n \rightarrow \infty} \mathbb{P}\{|X_n - X| > \varepsilon\} = 0$ . Atunci

$$F(x_0 - \varepsilon) \leq \liminf_{n \rightarrow \infty} F_n(x_0). \quad (3.1)$$

Apoi, pentru  $n \geq 1$ , avem

$$\{X_n \leq x_0\} \setminus \{|X_n - X| > \varepsilon\} \subset \{X_n \leq x_0\} \setminus \{X_n < X - \varepsilon\} \subset \{X \leq x_0 + \varepsilon\},$$

de unde

$$F_n(x_0) - \mathbb{P}\{|X_n - X| > \varepsilon\} \leq \mathbb{P}(\{X_n \leq x_0\} \setminus \{|X_n - X| > \varepsilon\}) \leq F(x_0 + \varepsilon).$$

Pe baza ipotezei, rezultă

$$\limsup_{n \rightarrow \infty} F_n(x_0) \leq F(x_0 + \varepsilon). \quad (3.2)$$

Din (3.1), (3.2) și continuitatea lui  $F$  în  $x_0$ , obținem  $\lim_{n \rightarrow \infty} F_n(x_0) = F(x_0)$ . Deci  $X_n \xrightarrow{d} X$ .

2. Presupunem  $X_n \xrightarrow{a.s.} X$ . Avem

$$\omega \in \{X_n \rightarrow X\} \Leftrightarrow \forall \varepsilon > 0, \exists n \geq 1, \forall k \geq n : |X_n(\omega) - X(\omega)| < \varepsilon.$$

Conform ipotezei, rezultă

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} \bigcap_{p=0}^{\infty} \{|X_{n+p} - X| < \varepsilon\}\right) = 1, \forall \varepsilon > 0,$$

de unde

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\bigcap_{p=0}^{\infty} \{|X_{n+p} - X| < \varepsilon\}\right) = 1, \forall \varepsilon > 0.$$

Cum  $\bigcap_{p=0}^{\infty} \{|X_{n+p} - X| < \varepsilon\} \subset \{|X_n - X| < \varepsilon\}$ , vom deduce

$$\lim_{n \rightarrow \infty} \mathbb{P}\{|X_n - X| < \varepsilon\} = 1, \forall \varepsilon > 0,$$

sau, trecând la evenimentele contrare,

$$\lim_{n \rightarrow \infty} \mathbb{P}\{|X_n - X| \geq \varepsilon\} = 0, \forall \varepsilon > 0.$$

Rezultă  $X_n \xrightarrow{p} X$ .

3. Implicația rezultă din inegalitatea lui Markov. Astfel, pentru oricare  $a > 0$ , avem

$$\mathbb{P}\{|X_n - X| > a\} \leq \frac{\mathbb{E}(|X_n - X|^k)}{a^k} \rightarrow 0, \text{ pentru } n \rightarrow \infty.$$

□

### 3.4 Legile numerelor mari

Legea numerelor mari reflectă următoare proprietate: *frecvența de apariție a unui eveniment într-un șir de experiențe identice, independente, tinde către probabilitatea de realizare a evenimentului în fiecare experiență*. Proprietatea a fost descrisă pentru prima dată la

sfârșitul sec. al XVI-lea de matematicianul italian Gerolamo Cardano (1501-1576). Formalizarea matematică (pentru variabile aleatoare binare) ca o *lege a numerelor mari* i se datorează lui Jacob Bernoulli (publicată în lucrarea *Ars conjectandi*, 1713). În 1837, S.D. Poisson a descris-o sub numele de "la Loi des grands nombres". Contribuții importante la demonstrarea riguroasă și extinderea rezultatului sunt datorate lui Chebyshev (demonstrarea legii slabe a numerelor mari, 1837), Markov, Borel (demonstrarea legii tari a numerelor mari, 1909), Cantelli, Kolmogorov și Khinchin.

Formalizarea Bernoulli a fenomenului observat de Cardano este următoarea. Să considerăm că, într-o experiență, un anumit eveniment  $A$  se produce cu probabilitatea  $p = \mathbb{P}(A)$ . Fie șirul  $(X_n)_{n \geq 1}$  de variabile aleatoare Bernoulli, independente și identic distribuite (iid), asociate șirului de experiențe considerat, având distribuția comună

$$X_n : \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}, \quad n \in \mathbb{N}^*.$$

Notăm  $S_n = X_1 + X_2 + \dots + X_n$  care indică numărul de apariții (realizări) ale evenimentului  $A$  în  $n$  experiențe. Frecvența de realizare a evenimentului  $A$  este deci  $S_n/n$ . Fenomenul descris de legea numerelor mari este prin urmare

$$\frac{S_n}{n} \rightarrow p = \mathbb{E}(X_1).$$

Convergența frecvenței de apariție a evenimentului la probabilitatea sa se poate realiza în sensul unui tip de convergență slab (lege slabă a numerelor mari) sau în sensul unui tip de convergență tare (lege tare a numerelor mari). Rezultatul este extins la variabile aleatoare cu medie și dispersie finite.

**Teorema 3.4.1.** (*Legea slabă a numerelor mari*)

Fie  $(X_n)_{n \geq 1}$  un șir de variabile aleatoare independente și identic distribuite (iid), cu  $\mathbb{E}(X_1) = \mu$  și  $V(X_1) = \sigma^2$ . Notăm  $S_n = X_1 + X_2 + \dots + X_n$ ,  $n \in \mathbb{N}^*$ . Atunci are loc convergența în probabilitate

$$\frac{S_n}{n} \xrightarrow{p} \mu.$$

*Demonstrație.* Vom interpreta  $\mu = \mathbb{E}(X_n)$ ,  $n \in \mathbb{N}^*$ , ca o variabilă aleatoare constantă, care ia valoarea  $\mu$  cu probabilitatea 1. Avem  $\mathbb{E}(S_n) = \sum_{k=1}^n \mathbb{E}(X_k) = n\mu$  și  $V(S_n) = \sum_{k=1}^n V(X_k) = n\sigma^2$ . Fie  $\varepsilon > 0$ , arbitrar. Conform inegalității lui Chebyshev,

$$\mathbb{P} \left\{ \left| \frac{S_n}{n} - \mu \right| > \varepsilon \right\} = \mathbb{P} \{ |S_n - \mathbb{E}(S_n)| > n\varepsilon \} \leq \frac{V(S_n)}{n^2\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}.$$

Rezultă

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ \left| \frac{S_n}{n} - \mu \right| > \varepsilon \right\} = 0.$$

Cum  $\varepsilon > 0$  este arbitrar, obținem concluzia.  $\square$

Menținăm că legea slabă a numerelor poate fi formulată pentru șiruri de variabile aleatoare independente (dar neidentic distribuite) cu dispersii uniform marginite (Chebyshev), respectiv pentru șiruri de variabile de v.a. cu proprietatea  $V(S_n)/n^2 \rightarrow 0$  (Markov). Prezentăm (fără) demonstrație și o versiune a *legii tari a numerelor mari*.

**Teorema 3.4.2.** (*Legea tare a numerelor mari*)

Fie  $(X_n)_{n \geq 1}$  un șir de variabile aleatoare independente și identic distribuite (iid), din spațiul  $L^4$  ( $\mathbb{E}(|X_1|^4) < \infty$ ) cu  $\mathbb{E}(X_1) = \mu$ . Fie  $S_n = X_1 + X_2 + \dots + X_n$ ,  $n \in \mathbb{N}^*$ . Atunci

$$\frac{S_n}{n} \xrightarrow{\text{a.s.}} \mu.$$

### 3.5 Teorema limită centrală

Teorema limită centrală, în versiunea clasică, stabilește că sumele parțiale "normalizate" ale unui șir de variabile aleatoare iid, cu dispersie finită, tind în distribuție către legea normală (gaussiană). Rezultatul admite numeroase extinderi relativ la șiruri de variabile aleatoare heterogene, neindependente, supuse unor anumite condiții. De asemenea, rezultatul se extinde la șiruri de vectori aleatori.

Prima versiune a acestei teoreme a fost formulată de Abraham de Moivre (1733) pentru variabile aleatoare de tip Bernoulli, cu  $p = 1/2$ ). Pierre-Simon Laplace generalizează rezultatul în lucrarea *Theorie Analytique des Probabilités* (1812), constatând apropierea distribuției binomiale de distribuția normală. În 1901, matematicianul rus Aleksandr Lyapunov a definit în termeni generali și a demonstrat riguros *teorema limită centrală*. Teorema limită centrală este considerată rezultatul principal al teoriei probabilităților.

Enunțăm pentru început rezultatul datorat lui de Moivre și Laplace relativ la șiruri iid de v. a. Bernoulli.

**Teorema 3.5.1.** (*Teorema de Moivre-Laplace*) Fie  $(X_n)_{n \geq 1}$  un șir de variabile aleatoare Bernoulli independente și identic distribuite (iid), de parametru  $p$ , având media comună  $p$  și dispersia comună  $pq$  (unde  $q=1-p$ ). Pentru  $n \in \mathbb{N}^*$ , notăm  $S_n = \sum_{k=1}^n X_k$  și

$$I_n = \left\{ \frac{k - np}{\sqrt{npq}}, k = 0, 1, \dots, n \right\}.$$

Atunci, pentru oricare interval  $[a, b] \subset \mathbb{R}$ , are loc:

$$\lim_{n \rightarrow \infty} \left( \sup_{x \in I_n \cap [a, b]} \left| \sqrt{2\pi npq} \cdot \mathbb{P} \left\{ \frac{S_n - np}{\sqrt{npq}} = x \right\} - e^{-\frac{x^2}{2}} \right| \right) = 0$$

Demonstrația se bazează pe aproximarea factorialului dată de formula lui Stirling

$$n! = \sqrt{2n\pi} \left( \frac{n}{e} \right)^n e^{\theta_n},$$

unde  $0 < \theta_n < \frac{1}{12n}$ ,  $n \geq 1$ . Din Teorema de Moivre-Laplace se deduce o versiune particulară a Teoremei limită centrală. Enunțul clasic general al acestei teoreme este prezentat în continuare.

**Teorema 3.5.2.** (*Teorema limită centrală*) Fie  $(X_n)_{n \geq 1}$  un șir de variabile aleatoare independente și identic distribuite (iid), cu  $\mathbb{E}(X_1) = \mu$  și  $V(X_1) = \sigma^2$ . Considerăm șirul de variabile aleatoare  $S_n = X_1 + X_2 + \dots + X_n$ ,  $n \in \mathbb{N}^*$ . Atunci:

1.

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ a \leq \frac{S_n - n\mu}{\sigma\sqrt{n}} \leq b \right\} = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{x^2}{2}}, \forall a, b \in \mathbb{R}, a < b;$$

2. (versiunea Lindeberg-Lévy) Are loc următoarea convergență în distribuție către o variabilă aleatoare gaussiană:

$$\frac{\sqrt{n}}{\sigma} \left( \frac{S_n}{n} - \mu \right) \xrightarrow{d} X,$$

unde  $X \in N(0, 1)$ .

*Demonstrație.* (schită)

Considerăm șirul de v. a. iid  $Y_n = \frac{X_n - \mu}{\sigma}$ ,  $n \geq 1$ , de medie comună 0 și dispersie comună 1. Atunci, conform Teoremei 2.9.1, 7, funcția caracteristică a variabilelor aleatoare  $Y_n$  este de forma

$$\varphi_{Y_n}(t) = 1 - \frac{t^2}{2} + o(t^2), \quad t \rightarrow 0.$$

Fie

$$Z_n = \frac{\sum_{k=1}^n Y_k}{\sqrt{n}} = \frac{S_n - n\mu}{\sigma\sqrt{n}}, \quad n \geq 1.$$

Pe baza proprietăților funcției caracteristice (Teorema 2.9.1), obținem

$$\varphi_{Z_n}(t) = \left[ \varphi_{Y_1} \left( \frac{t}{\sqrt{n}} \right) \right]^n = \left[ 1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right) \right]^n \xrightarrow{n \rightarrow \infty} e^{-\frac{t^2}{2}}.$$

Dar, pentru  $X \in N(0, 1)$ , avem  $\varphi_X(t) = e^{-\frac{t^2}{2}}$ ,  $t \in \mathbb{R}$  (a se vedea Exemplul 3.10.1). Conform teoremei de unicitate (Teorema 2.9.2) se obține  $Z_n \xrightarrow{d} X$ . Astfel, teorema limită centrală este demonstrată.  $\square$

### 3.6 Rezumat

**Inegalitatea lui Markov** Fie  $X \in L^n(\Omega)$ , unde  $n \in \mathbb{N}^*$ . Atunci

$$\mathbb{P}\{|X| > a\} \leq \frac{\mathbb{E}(|X|^n)}{a^n}, \quad \forall a > 0.$$

**Inegalitatea lui Cebîșev (Chebyshev)** Fie  $X \in L^2(\Omega)$ , având media  $\mathbb{E}(X) = \mu$  și dispersia  $V(X) = \sigma^2$ . Atunci

$$\mathbb{P}\{|X - \mu| > a\} \leq \frac{\sigma^2}{a^2}, \quad \forall a > 0.$$

Definim următoarele tipuri de convergență ale șirului  $(X_n)_{n \geq 1}$  către limita  $X$ :

1. șirul  $(X_n)_{n \geq 1}$  converge în distribuție (repartiție) la  $X$ , notat prin

$$X_n \xrightarrow{d} X,$$

dacă  $\lim_{n \rightarrow \infty} F_n(x_0) = F(x_0)$ , pentru orice punct de continuitate  $x_0 \in \mathbb{R}$  al funcției  $F$ ;

2. șirul  $(X_n)_{n \geq 1}$  converge în probabilitate la  $X$ , notat prin

$$X_n \xrightarrow{p} X,$$

dacă  $\lim_{n \rightarrow \infty} \mathbb{P}\{|X_n - X| > \varepsilon\} = 0, \quad \forall \varepsilon > 0$ ;

3. șirul  $(X_n)_{n \geq 1}$  converge aproape sigur la  $X$ , notat prin

$$X_n \xrightarrow{a.s.} X,$$

dacă  $\mathbb{P}\{X_n \rightarrow X\} = 1$ ;

4. șirul  $(X_n)_{n \geq 1}$  converge în spațiul  $L^k(\Omega)$  la  $X$ , unde  $k \in \mathbb{N}^*$ , notat prin

$$X_n \xrightarrow{L^k} X,$$

dacă  $\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|^k) = 0$ .

Au loc implicațiile

- $X_n \xrightarrow{p} X \implies X_n \xrightarrow{d} X$ ;
- $X_n \xrightarrow{a.s.} X \implies X_n \xrightarrow{p} X$ ;
- $X_n \xrightarrow{L^k} X \implies X_n \xrightarrow{p} X$ .



Implicațiile reciproce sunt false.

**Legea slabă a numerelor mari** Fie  $(X_n)_{n \geq 1}$  un șir de variabile aleatoare independente și identic distribuite (iid), cu  $\mathbb{E}(X_1) = \mu$  și  $V(X_1) = \sigma^2$ . Notăm  $S_n = X_1 + X_2 + \dots + X_n$ ,  $n \in \mathbb{N}^*$ . Atunci are loc convergența în probabilitate

$$\frac{S_n}{n} \xrightarrow{p} \mu.$$

**Legea tare a numerelor mari** Fie  $(X_n)_{n \geq 1}$  un șir de variabile aleatoare independente și identic distribuite (iid), din spațiul  $L^4$  ( $\mathbb{E}(|X_1|^4) < \infty$ ) cu  $\mathbb{E}(X_1) = \mu$ . Fie  $S_n = X_1 + X_2 + \dots + X_n$ ,  $n \in \mathbb{N}^*$ . Atunci

$$\frac{S_n}{n} \xrightarrow{a.s.} \mu.$$

**Teorema limită centrală** Fie  $(X_n)_{n \geq 1}$  un șir de variabile aleatoare independente și identic distribuite (iid), cu  $\mathbb{E}(X_1) = \mu$  și  $V(X_1) = \sigma^2$ . Considerăm șirul de variabile aleatoare  $S_n = X_1 + X_2 + \dots + X_n$ ,  $n \in \mathbb{N}^*$ . Atunci:

1.

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ a \leq \frac{S_n - n\mu}{\sigma\sqrt{n}} \leq b \right\} = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{x^2}{2}}, \quad \forall a, b \in \mathbb{R}, \quad a < b;$$

2. (versiunea Lindeberg-Lévy) Are loc următoarea convergență în distribuție către o variabilă aleatoare gaussiană:

$$\frac{\sqrt{n}}{\sigma} \left( \frac{S_n}{n} - \mu \right) \xrightarrow{d} X,$$

unde  $X \in N(0, 1)$ .

### 3.7 Test

1. Să se enunțe și să se demonstreze Legea slabă a numerelor mari.
2. Să se enunțe Teorema limită centrală, adaptată pentru variabile aleatoare de tip geometric.
3. Să se determine funcția de repartiție a variabilei aleatoare  $X$  care admite funcția caracteristică

$$\varphi_X(t) = \frac{1}{4} (1 + e^{it})^2.$$

4. Inegalitatea lui Cebîșev aplicată variabilei aleatoare  $X$ , cu media  $E(X) = 3$  și dispersia  $V(X) = \sigma^2$ , stabilește:

$$\mathbb{P}\{|X - 3| \geq 2\} \leq 0,16.$$

Să se determine  $\sigma$ .

5. La un concurs de biatlon, un sportiv nimereste ținta cu probabilitatea de  $\frac{4}{5}$ . Știind că sportivul execută în concurs 25 de trageri, să se arate că șansa ca acesta să nimerască ținta de cel puțin 15 ori este mai mare de 85%.
6. Probabilitatea ca un monitor de calculator să nu aibă rezoluția acceptabilă este de 0,1. S-au cumpărat 1000 de monitoare. Care este probabilitatea ca mai mult de 100 monitoare să nu fie acceptabile? (Notă: se va utiliza aproximarea oferită de Teorema limită centrală.)

# Capitolul 4

## Elemente de statistică matematică

### 4.1 Introducere

Statistica matematică este o ramură importantă a matematicii, care utilizează rezultatele oferite de teoria probabilităților. Progresul în societate, în particular în știință, este adeseori datorat *experimentului*. Cercetătorul realizează o experiență și obține o serie de date, pe baza cărora generează rezultatele experienței la o clasă de experiențe similare. Acest tip de extindere se datorează unui raționament de tip *inductiv* (obținerea unor informații generale din analiza unor informații particulare). Statistica analizează date concrete, locale, obținute experimental, pentru a prognoza date cu caracter general, a descoperi legile care guvernează fenomenul aleator studiat. În același timp, statistica se preocupă de verosimilitatea matematică a prognozei, măsurând cu mijloace matematice gradul de încredere în rezultatele generale propuse.

Prezentarea de față are ca obiectiv familiarizarea cu câteva noțiuni de bază din teoria statisticii matematice, precum: populație statistică, sondaj, eșantion, estimator și caracteristicile sale. Pentru simplificarea expunerii, ne vom rezuma la descrierea unor elemente de *statistica eșantioanelor Bernoulli*.

### 4.2 Noțiuni de bază

Statistica operează cu noțiuni specifice. Astfel, **populația statistică** reprezintă mulțimea tuturor elementelor avute în vedere în cadrul unui **studiu statistic**. De regulă, pentru o populație mare, studiul statistic se realizează prin **sondaj**. Sondajul constă în observarea (examinarea, chestionarea) unei părți a populației, numită **eșantion**. Numărul elementelor unui eșantion (obținut prin sondaj și examinat) se numește **volumul eșantionului**. De regulă, volumul eșantionului se stabilește (pe baza unor evaluări matematice) astfel încât să poată furniza date generale concludente/veridice. Scopul studiului statistic este **estimarea** unei proprietăți/particularități a populației statistice. Funcția matematică care realizează estimarea se numește **estimator**. Apelând la modelul particular al eșantioanelor Bernoulli, vom trece în revistă calitățile impuse unui estimator de calitate.

### 4.3 Estimatori. Proprietăți

Cel mai simplu studiu statistic se referă la analiza cazului binar: fiecare individ (element) al populației statistice are valoarea 1 sau 0 (răspunde cu 1 sau 0 la un chestionar). Ne interesează proporția indivizilor cu valoarea 1 în cadrul întregii populații statistice. Examinarea/chestionarea indivizilor prin sondaj se modelează printr-o variabilă aleatoare "observabilă", care indică numărul indivizilor care valorează 1 într-un eșantion de volum  $n$ . La o populație "mică", este logic să apelăm la modelul oferit de legea hipergeometrică, întrucât extragerea unui eșantion dintr-o populație mică afectează în mod cert proporția valorii 1 în cadrul populației nesondate. În schimb, dacă volumul populației este "mare" în raport cu volumul eșantionului atunci este rezonabil să considerăm că fiecare element al populației statistice se reprezintă printr-o variabilă aleatoare Bernoulli  $X$ , cu distribuția

$$X : \begin{pmatrix} 0 & 1 \\ 1 - \theta & \theta \end{pmatrix},$$

unde parametrul  $\theta$  (necunoscut) reprezintă proporția valorii 1 în populația statistică. Astfel,  $\mathbb{P}\{X = 1\} = \theta$  reprezintă șansa ca elementul  $X$  să aibă valoarea 1. Evident,  $\mathbb{P}\{X = 0\} = 1 - \theta$  reprezintă șansa ca  $X$  să ia valoarea 0. Obiectul studiului statistic întreprins constă în *estimarea* parametrului  $\theta$ , din observarea unui eșantion de volum  $n$ ,  $(X_1, X_2, \dots, X_n)$ , reprezentând un vector aleator cu componentele variabile aleatoare iid, de tip  $Bin(1, \theta)$ . **Distribuția eșantionului** se definește distribuția comună a v. a.  $X_1, X_2, \dots, X_n$ .

O **statistică** (sau un **estimator**) se definește ca o funcție a variabilelor aleatoare "observabile" (cele ale n-eșantionului), deci care nu depinde de parametri necunoscuți.

Pentru evaluarea apriorică a parametrului necunoscut  $\theta$  se propune estimatorul **media empirică**, definit prin:

$$\bar{X} = \frac{S_n}{n}, \text{ unde } S_n = X_1 + X_2 + \dots + X_n.$$

În fapt, media empirică exprimă frecvența de apariție a valorii 1, deci, intuitiv, pare a oferi o bună evaluare a parametrului  $\theta$ . Descriem în continuare proprietățile principale ale mediei empirice  $\bar{X}$ , ca estimator a lui  $\theta$ .

1.  $\bar{X}$  este un estimator fără abatere a lui  $\theta$ :  $\mathbb{E}_\theta(\bar{X}) = \theta$ ,  $\forall \theta \in (0, 1)$ .

*Demonstrație.*  $\mathbb{E}_\theta(\bar{X}) = [\sum_{k=1}^n \mathbb{E}_\theta(X_k)] / n = (n\theta) / n = \theta$ .

2.  $\bar{X}$  este unicul estimator fără abatere a lui  $\theta$ , care depinde de  $S_n$ .

*Demonstrație.* Fie  $g : \{0, 1, 2, \dots, n\} \rightarrow \mathbb{R}$ , astfel încât

$$\theta = \mathbb{E}_\theta[g(S_n)] = \theta, \quad \forall \theta \in (0, 1). \quad (4.1)$$

Avem

$$\mathbb{E}_\theta[g(S_n)] = \sum_{k=0}^n g(k) \mathbb{P}\{S_n = k\} = \sum_{k=0}^n g(k) C_n^k \theta^k (1 - \theta)^{n-k},$$

iar pe de altă parte

$$\theta = \mathbb{E}_\theta(\overline{X}) = \mathbb{E}_\theta\left(\frac{S_n}{n}\right) = \sum_{k=0}^n \frac{k}{n} \mathbb{P}\{S_n = k\} = \sum_{k=0}^n \frac{k}{n} C_n^k \theta^k (1-\theta)^{n-k}.$$

Atunci, conform (4.1), obținem

$$\sum_{k=0}^n \left(g(k) - \frac{k}{n}\right) C_n^k \left(\frac{\theta}{1-\theta}\right)^k = 0, \quad \forall \theta \in (0, 1).$$

Rezultă că polinomul  $f = \sum_{k=0}^n \left(g(k) - \frac{k}{n}\right) C_n^k X^k$  este identic nul.

Prin urmare  $g(k) = k/n$ ,  $k = 0, 1, \dots, n$ , deci  $g(S_n) = \overline{X}$ .

**3.**  $\overline{X}$  este estimatorul lui  $\theta$  de maximă verosimilitate.

*Demonstrație.* Să presupunem că au fost observate valorile  $(x_1, x_2, \dots, x_n) \in \{0, 1\}^n$ . Notăm  $s_n = \sum_{k=1}^n x_k$ . Probabilitatea de a observa aceste valori este  $\theta^{s_n} (1-\theta)^{n-s_n}$ . Atunci, cea mai verosimilă valoare pe care o poate lua  $\theta$  este cea care maximizează funcția

$$L : [0, 1] \rightarrow [0, 1], \quad L(u) = u^{s_n} (1-u)^{n-s_n}.$$

Presupunem  $0 < s_n < n$ . Avem

$$L'(u) = L(u) \frac{s_n - nu}{u(1-u)}.$$

Rădăcina derivatei lui  $L$  este  $u_0 = \frac{s_n}{n}$ . Urmărind semnul derivatei, deducem că  $L$  își atinge maximul în  $u_0$ . Rezultă că  $\overline{X} = S_n/n$  este estimatorul de verosimilitate maximă.

**4.** Când talia eșantionului tinde la infinit,  $\overline{X}$  converge la  $\theta$  cu o rată exponențială.

*Demonstrație.* Vom remarca în primul rând că, pe baza inegalității lui Chebyshev,

$$\overline{X} \xrightarrow{p} \theta \text{ (legea slabă numerelor mari).}$$

Pe de altă parte, conform *Teoremei limită centrală* (Teorema 3.5.2),

$$\sqrt{\frac{n}{\theta(1-\theta)}} (\overline{X} - \theta) \xrightarrow{d} X,$$

unde  $X \in N(0, 1)$ .

Faptul că rata convergenței este exponențială se deduce din *Teorema marilor deviații*, pe care nu o vom include în această prezentare.

**5.** Riscul pătratic mediu al estimatorului  $\overline{X}$  a lui  $\theta$  converge la 0.

*Demonstrație.* Riscul pătratic mediu al estimatorului  $\bar{X}$  este definit prin  $\mathbb{E}_\theta (\bar{X} - \theta)^2$ . Avem

$$\mathbb{E}_\theta (\bar{X} - \theta)^2 = \mathbb{E}_\theta \left( \frac{S_n}{n} - \theta \right)^2 = \frac{1}{n^2} \mathbb{E}_\theta (S_n - n\theta)^2 = \frac{n}{n^2} V(X_1) = \frac{\theta(1-\theta)}{n} \leq \frac{1}{4n},$$

de unde  $\mathbb{E}_\theta (\bar{X} - \theta)^2 \xrightarrow{n \rightarrow \infty} 0$ .

**6.** Abaterea lui  $\bar{X}$  față de  $\theta$  poate fi evaluată prin Teorema limită centrală.

*Demonstrație.* Fie  $a > 0$ . Pentru  $n \geq \frac{4\theta(1-\theta)}{a^2}$ , avem  $\frac{a\sqrt{n}}{\sqrt{\theta(1-\theta)}} \geq 2$ , de unde

$$\begin{aligned} \mathbb{P}_\theta \{ |\bar{X} - \theta| \geq a \} &= \mathbb{P} \left\{ \left| \frac{S_n - n\theta}{\sqrt{n\theta(1-\theta)}} \right| \geq \frac{a\sqrt{n}}{\sqrt{\theta(1-\theta)}} \right\} \\ &\leq \mathbb{P} \left\{ \left| \frac{S_n - n\theta}{\sqrt{n\theta(1-\theta)}} \right| \geq 2 \right\} \approx \frac{1}{\sqrt{2\pi}} \int_{|x| \geq 2} e^{-\frac{x^2}{2}} dx < 0,05. \end{aligned}$$

## 4.4 Estimatori bayesieni

Media empirică  $\bar{X}$  este o estimare judicioasă a parametrului  $\theta$  în absența oricăror informații suplimentare. Dar problema se modifică în cazul unor informații apriorice despre  $\theta$ . Dacă aceste informații există, mai precis, dacă se cunoaște o măsură de probabilitate pe  $[0, 1]$  reprezentând distribuția valorilor posibile ale lui  $\theta$ , atunci se va cerceta estimatorul  $g(S_n)$  a lui  $\theta$  care minimizează riscul pătratic mediu, ținând cont de această distribuție.

Fie  $D$  o mulțime numărabilă din  $[0, 1]$ , iar  $\rho : D \rightarrow [0, 1]$  o măsură de probabilitate pe  $D$ , cu  $\sum_{x \in D} \rho(x) = 1$ . Pentru o funcție  $g$  definită pe  $\{0, 1, \dots, n\}$  cu valori în  $[0, 1]$ , riscul pătratic mediu al estimatorului  $g(S_n)$  este

$$\begin{aligned} \sum_{\theta \in D} \rho(\theta) \mathbb{E}_\theta [g(S_n) - \theta]^2 &= \sum_{\theta \in D} \rho(\theta) \sum_{k=0}^n (g(k) - \theta)^2 C_n^k \theta^k (1-\theta)^{n-k} \\ &= \sum_{k=0}^n C_n^k \left( \sum_{\theta \in D} \rho(\theta) (g(k) - \theta)^2 \theta^k (1-\theta)^{n-k} \right). \end{aligned}$$

Pentru  $k \in \{0, 1, \dots, n\}$ , considerăm funcția  $\psi_k : [0, 1] \rightarrow [0, \infty)$ , definită prin

$$\psi_k(x) = \sum_{\theta \in D} \rho(\theta) \theta^k (1-\theta)^{n-k} (x - \theta)^2, \quad x \in [0, 1].$$

Avem

$$\psi'_k(x) = 2 \sum_{\theta \in D} \rho(\theta) \theta^k (1-\theta)^{n-k} (x - \theta), \quad x \in [0, 1].$$

Studiind semnul derivatei, deducem că  $\psi_k$  atinge minimumul în punctul

$$x_k = \frac{\sum_{\theta \in D} \rho(\theta) \theta^{k+1} (1-\theta)^{n-k}}{\sum_{\theta \in D} \rho(\theta) \theta^k (1-\theta)^{n-k}} \in [0, 1].$$

Vom defini deci *estimatorul bayesian* a lui  $\theta$  de risc pătratic mediu minim:

$$g(S_n) = \frac{\sum_{\theta \in D} \rho(\theta) \theta^{S_n+1} (1-\theta)^{n-S_n}}{\sum_{\theta \in D} \rho(\theta) \theta^{S_n} (1-\theta)^{n-S_n}}.$$

Similar, dacă se cunoaște "a priori" densitatea de probabilitate  $f$  a lui  $\theta$  pe intervalul  $[0, 1]$ , atunci *estimatorul bayesian* a lui  $\theta$ , dependent de  $S_n$ , având *riscul pătratic minim*, va fi

$$g(S_n) = \frac{\int_0^1 \theta^{S_n+1} (1-\theta)^{n-S_n} f(\theta) d\theta}{\int_0^1 \theta^{S_n} (1-\theta)^{n-S_n} f(\theta) d\theta}.$$

## 4.5 Rezumat

Statistica matematica utilizează rezultatele oferite de teoria probabilităților pentru a generaliza rezultatele unei experiențe la o clasă de experiențe similare. Acest tip de extindere se datorează unui raționament de tip *inductiv* (obținerea unor informații generale din analiza unor informații particulare). Statistica analizează date concrete, locale, obținute experimental, pentru a prognoza date cu caracter general, a descoperi legile care guvernează fenomenul studiat.

Noțiuni specifice:

- **populația statistică** reprezintă mulțimea tuturor elementelor avute în vedere în cadrul unui **studiu statistic**;
- **sondajul** reprezintă examinarea (chestionarea) unei părți a populației statistice, numită **eșantion**;
- numărul elementelor unui eşantion (obținut prin sondaj și examinat) se numește **volumul eşantionului**;
- scopul unui studiu statistic este **estimarea** unei proprietăți/particularități a populației statistice. Funcția matematică care realizează estimarea se numește **estimator**;
- o **statistică** (sau un **estimator** se definește ca o funcție de variabilelor aleatoare observabile (cele ale  $n$ -eșantionului) și nu depinde de parametrii necunoscuți.

### Statistica eşantioanelor Bernoulli.

Modelare: fiecare element al populației statistice se reprezintă printr-o variabilă aleatoare Bernoulli  $X$ , cu distribuția

$$X : \begin{pmatrix} 0 & 1 \\ 1 - \theta & \theta \end{pmatrix},$$

Pentru evaluarea apriorică a parametrului necunoscut  $\theta$  se propune estimatorul **media empirică**, definit prin:

$$\bar{X} = \frac{S_n}{n}, \text{ unde } S_n = X_1 + X_2 + \dots + X_n.$$

Media empirică exprimă frecvența de apariție a valorii 1, deci oferă o evaluare a parametrului  $\theta$ . Proprietățile principale ale mediei empirice  $\bar{X}$ , ca estimator a lui  $\theta$ .

1.  $\bar{X}$  este un estimator fără abatere a lui  $\theta$ :  $\mathbb{E}_\theta(\bar{X}) = \theta$ ,  $\forall \theta \in (0, 1)$ .
2.  $\bar{X}$  este unicul estimator fără abatere a lui  $\theta$ , care depinde de  $S_n$ .
3.  $\bar{X}$  este estimatorul lui  $\theta$  de maximă verosimilitate
4. Când talia eşantionului tinde la infinit,  $\bar{X}$  converge la  $\theta$  cu o rată exponențială.
5. Riscul pătratic mediu al estimatorului  $\bar{X}$  a lui  $\theta$  converge la 0.
6. Abaterea lui  $\bar{X}$  față de  $\theta$  poate fi evaluată prin Teorema limită centrală.

Definim estimatorul bayesian a lui  $\theta$ , de risc pătratic mediu minim:

$$g(S_n) = \frac{\sum_{\theta \in D} \rho(\theta) \theta^{S_n+1} (1-\theta)^{n-S_n}}{\sum_{\theta \in D} \rho(\theta) \theta^{S_n} (1-\theta)^{n-S_n}}.$$

Dacă  $\theta$  admite densitatea de probabilitate  $f$  pe  $[0, 1]$ , atunci estimatorul bayesian a lui  $\theta$  este

$$g(S_n) = \frac{\int_0^1 \theta^{S_n+1} (1-\theta)^{n-S_n} f(\theta) d\theta}{\int_0^1 \theta^{S_n} (1-\theta)^{n-S_n} f(\theta) d\theta}.$$



## 4.6 Noțiuni de statistică descriptivă

### 4.6.1 Concepte de bază

- **Statistica**, ramură a matematicii, studiază metodele de înregistrare, descriere și analiză a datelor experimentale referitoare la un anumit fenomen în scopul formulării unor previziuni.
- **Populația statistică** este mulțimea (în sens matematic) care face obiectul unui anumit **studiu statistic**.
- **Unitate statistică** (indivd) este un element component al unei populații statistice.
- **Caracteristică statistică** este una din însușirile unității statistice.  
O caracteristică cantitativă este *măsurabilă*, iar una calitativă este *atributivă*.  
Un studiu statistic vizează una sau mai multe caracteristici statistice ale indivizilor unei populații statistice.
- **Eșantionul** este o submulțime a populației statistice, obținută printr-o **selecție**, pentru care se realizează evaluarea caracteristicii statistice. Pentru unele studii statistice, eşantionul reprezintă întreaga populație statistică. Numărul de elemente al eşantionului se numește **volumul** (efectivul) eşantionului.
- **Sondajul** este acțiunea de prevalare și înregistrare a valorilor uneia sau mai multor caracteristici statistice ale indivizilor unui eşantion fixat.
- **Tabelul statistic** conține înregistrarea valorilor numerice (datelor experimentale), numite **valori observate** obținute prin măsurarea caracteristicii tuturor unităților statistice ale eşantionului selecționat.
- **Frecvența relativă** a unei valori a caracteristicii este raportul dintre numărul indivizilor eşantionului pentru care s-a înregistrat valoarea respectivă și volumul eşantionului.
- **Distribuția statistică empirică** reprezintă repartitia valorilor observate ale caracteristicii pentru eşantionul selecționat (înregistrate în tabelul statistic). Din punct de vedere matematic, distribuția statistică (empirică) este funcția care realizează corespondența între numerele reale, obținute ca valori observate ale caracteristicii, și **frecvența relativă** a înregistrării lor.
- **Distribuțiile (repartițiile) statistice teoretice** reprezintă modele matematice idealizate ale distribuțiilor empirice. Concret, o distribuție statistică teoretică este descrisă de o funcție  $f : \mathbb{R} \rightarrow [0, 1]$  cu proprietatea  $\int_{-\infty}^{\infty} f(x) dx = 1$ , numită **densitate de probabilitate**. Pentru anumite fenomene analizate statistic, distribuția empirică **tinde** la o anumită distribuție teoretică, dacă (ne imaginăm că) volumul eşantionului **tinde la infinit**.
- **Teoria probabilităților** operează cu noțiunile de *spațiu măsurabil*, *probabilitate* și *variabilă aleatoare*. O variabilă aleatoare este o funcție  $X$ , definită pe un spațiu măsurabil cu probabilitate, cu valori reale, având proprietatea că pentru orice număr

real  $x$  se poate evalua probabilitatea  $F(x)$  ca  $X$  să ia valori în intervalul  $(-\infty, x]$ , și anume:

$$F(x) = P\{X \leq x\} \in [0, 1].$$

Spunem că variabila aleatoare  $X$  are densitatea de probabilitate  $f$  dacă:

$$F(x) = \int_{-\infty}^x f(t) dt, \text{ pentru orice număr real } x$$

**Media** unei variabile aleatoare  $X$  cu densitatea de probabilitate  $f$  se calculează prin:

$$M(X) = \int_{-\infty}^{\infty} x f(x) dx$$

**Dispersia** unei variabile aleatoare  $X$  cu densitatea de probabilitate  $f$  se calculează prin:

$$\sigma^2(X) = \int_{-\infty}^{\infty} (x - m)^2 f(x) dx, \text{ unde } m = M(X)$$

Un caz particular îl constituie *variabilele aleatoare finite*. O astfel de variabilă aleatoare  $X$  are un număr finit de valori reale  $x_1 < x_2 < \dots < x_k$  cu probabilitățile  $p_1, p_2, \dots, p_k \in [0, 1]$ . Avem deci:

$$p_i = P\{X = x_i\}, \quad i = 1, 2, \dots, k; \quad p_1 + p_2 + \dots + p_k = 1.$$

În acest caz, media și respectiv dispersia variabilei aleatoare  $X$  se calculează după următoarele formule:

$$m = M(X) = x_1 p_1 + x_2 p_2 + \dots + x_k p_k = \sum_{i=1}^k x_i p_i$$


$$\sigma^2(X) = (x_1 - m)^2 p_1 + (x_2 - m)^2 p_2 + \dots + (x_k - m)^2 p_k = \sum_{i=1}^k (x_i - m)^2 p_i.$$

• **Exemple de distribuții (repartiții, legi) teoretice clasice:**

1. **Legea normală de medie  $m$  și dispersie  $\sigma^2$**  are densitatea de probabilitate:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-m)^2}{2\sigma^2}}, \quad x \in R$$

Graficul lui  $f$  are forma unui clopot, cunoscut sub denumirea de *clopotul lui Gauss*. Legea normală (sau legea lui *Gauss-Laplace*) joacă un rol central în teoria probabilităților, fiind *legea limită a sumelor normalizate ale șirurilor de variabile aleatoare independente și identic distribuite*.



Valorile unei

variabile aleatoare  $X$  cu distribuție normală de medie  $m$  și dispersie  $\sigma^2$  se "concentrează" cu o probabilitate de 95% în intervalul  $[m - 2\sigma, m + 2\sigma]$ , centrat în valoarea medie  $m$ . Mai precis avem:

$$P\{m - 2\sigma \leq X \leq m + 2\sigma\} = 0,9544 \dots$$

unde  $\sigma = \sqrt{\sigma^2}$  se numește **abaterea standard** a variabilei aleatoare  $X$ .

2. **Repartiția  $\chi^2$  cu  $m$  grade de libertate** are densitatea de probabilitate:

$$f(x) = \frac{1}{2^{\frac{m}{2}} \Gamma\left(\frac{m}{2}\right)} x^{\frac{m}{2}-1} e^{-\frac{x}{2}}, \quad x > 0$$

unde:

$$\Gamma\left(\frac{m}{2}\right) = \int_0^\infty x^{\frac{m}{2}-1} e^{-x} dx.$$

Dacă o variabilă aleatoare  $X$  are repartiția  $\chi^2$  cu  $m$  grade de libertate, atunci media și respectiv dispersia variabilei aleatoare sunt următoarele:

$$M(X) = m$$

$$\sigma^2(X) = 2m$$

Repartiția  $\chi^2$  are un rol important în statistica matematică în deducerea repartiției statistice a unor *estimatori* și în verificarea *ipotezelor statistice*.

#### 4.6.2 Tipuri de distribuții statistice empirice. Tabele statistice. Reprezentări grafice.

În cadrul unui studiu statistic, datele experimentale obținute prin măsurarea valorică a unei caracteristici a unui eșantion considerat sunt înregistrate într-un tabel statistic. Acesta evidențiază o anumită distribuție statistică. După natura repartiției valorilor înregistrate, distingem două tipuri de distribuții statistice empirice (experimentale).

1) **Tipul finit (sau discret)** de distribuție corespunde cazului în care, ipotetic, caracteristica măsurată poate lua un număr finit (sau numărabil) de valori. În continuare vom trata numai cazul finit.

Considerăm un eșantion fixat de volum  $n$ . Aceasta înseamnă că numărul de unități statistice pentru care se determină și se înregistrează valoarea caracteristicii este egal cu  $n$ . Să presupunem că valorile înregistrate ale caracteristicii sunt numerele reale  $x_1 < x_2 < \dots < x_k$  unde  $k$  este un număr natural cuprins între 1 și  $n$ .

Fiecarei valori realizate (înregistrate) a caracteristicii îi determinăm "frecvența" de apariție.

- **Frecvența absolută a valorii**  $x_i$  este numărul  $n_i$  de subiecți pentru care valoarea caracteristicii este  $x_i$ . Din definiție rezultă  $0 \leq n_i \leq n$  și  $\sum_{i=1}^k n_i = n$ , unde  $\sum_{i=1}^k n_i$  este notația simbolică a sumei  $n_1 + n_2 + \dots + n_k$ .
- **Frecvența relativă a valorii**  $x_i$  este numărul  $f_i = \frac{n_i}{n}$ . Constatăm că au loc relațiile:  $f_i \in [0, 1]$  și  $\sum_{i=1}^k f_i = 1$ .

- **Frecvența procentuală a valorii**  $x_i$  este numărul  $p_i = 100 \cdot \frac{n_i}{n} = 100 \cdot f_i$ .  
Avem  $p_i \in [0, 100]$  și  $\sum_{i=1}^k p_i = 100$ . Pentru a evidenția că  $p_i$  reprezintă o mărime procentuală, se folosește curent notația  $p_i \%$ .

Frecvențele determinate ale valorilor, indicând distribuția statistică empirică, pot fi centralizate în *tabelul frecvențelor* sau pot fi reprezentate grafic prin *diagrama de structură*, *histograma* și respectiv *poligonul frecvențelor*.

- **Diagrama de structură** ilustrează distribuția statistică empirică prin partiția unui disc în sectoare de cerc cu ariile proporționale cu frecvențele relative ale valorilor. Sectorul reprezentând valoarea  $x_i$  are unghiul de la centru de măsură  $\alpha_i = f_i \cdot 360^\circ$ .
- **Poligonul frecvențelor** se obține, într-un sistem de axe de coordonate, unind succesiv prin segmente punctele de coordonate  $(x_1, f_1), (x_2, f_2), \dots, (x_k, f_k)$ .
- **Histograma** ilustrează, într-un sistem de axe de coordonate, frecvențele relative (sau procentuale) ale valorilor  $x_i$  prin dreptunghiuri de înălțime  $f_i$  (respectiv  $p_i$ ) dispuse cu baza pe axa absciselor, în dreptul absciselor  $x_i$ .

**Exemplul 1** La o probă sportivă fiecare participant a efectuat 6 aruncări la coșul de baschet, realizând între 0 și 6 aruncări reușite. Rezultatele obținute de cei 40 de participanți sunt prezentate sintetic în tabelul următor:


numărul de aruncări reușite	0	1	2	3	4	5	6	
numărul de participanți	2	4	8	15	4	6	1	total 40

Volumul eșantionului considerat este  $n = 40$  iar numărul de valori ale caracteristicii este  $k = 7$ . Prezentăm tabelul frecvențelor, diagrama de structură, histograma și respectiv poligonul frecvențelor asociate studiului statistic considerat.


### A) Tabelul frecvențelor

valorile $x_i$	frecvențele		
	absolute ( $n_i$ )	relative ( $f_i$ )	procentuale ( $p_i \%$ )
0	2	0,050	5,0 %
1	4	0,100	10,0 %
2	8	0,200	20,0 %
3	15	0,375	37,5 %
4	4	0,100	10,0 %
5	6	0,150	15,0 %
6	1	0,025	2,5 %
	$\sum_{i=1}^7 n_i = 40$	$\sum_{i=1}^7 f_i = 1$	$\sum_{i=1}^7 p_i = 100$


### B) Diagrama de structură




## C) Histograma



## D) Poligonul frecvențelor



2) **Tipul continuu** de distribuție corespunde cazului când valorile caracteristicii sunt numere reale situate într-un anumit interval  $[a, b]$ . Pentru a grupa valorile caracteristicii, se fixează, ținând cont de specificul studiului statistic efectuat, un număr întreg  $k > 1$  și se împarte intervalul  $(a, b]$  în  $k$  subintervale de aceeași lungime  $l = \frac{b-a}{k}$ . Notăm, în ordine, aceste intervale  $I_1, I_2, \dots, I_k$ . Astfel,  $I_i = (a + \frac{(i-1)(b-a)}{k}, a + \frac{i(b-a)}{k}]$ ,  $i = 1, 2, \dots, k$ . Fie un eșantion fixat de volum  $n$  cu  $n > k$ . Fiecărui interval  $I_i$  i se asociază ”frecvența de apariție”; vom nota cu  $x_i$  valoarea ”centrală” a intervalului, adică  $x_i = a + \frac{(2i-1)(b-a)}{2k}$ , obținută făcând media aritmetică a capetelor intervalului  $I_i$  (a se vedea figura următoare).



- **Frecvența absolută a intervalului  $I_i$**  este numărul  $n_i$  de subiecți pentru care valoarea caracteristicii aparține intervalului  $I_i$ .
- **Frecvența relativă a intervalului  $I_i$**  este numărul  $f_i = \frac{n_i}{n}$ .
- **Frecvența procentuală a intervalului  $I_i$**  este numărul  $p_i = 100 \cdot f_i$ .

Frecvențele determinate ale valorilor, indicând distribuția statistică empirică, pot fi centralizate în *tabelul frecvențelor* sau pot fi reprezentate grafic prin *diagrama de structură*, *histograma* și respectiv *poligonul frecvențelor* care nu diferă de cele descrise pentru distribuții finite.

**Exemplul 2** La o probă contracronometru de ciclism au participat 148 de concurenți. După înregistrarea timpilor de parcurs, s-au grupat rezultatele în 6 intervale de câte 30" și s-au calculat frecvențele intervalelor, obținându-se următorul tabel:

**Tabelul frecvențelor**

intervalele $I_i$	valorile centrale $x_i$	frecvențele		
		absolute ( $n_i$ )	relative ( $f_i$ )	procentuale ( $p_i$ %)
$(48', 48'30"]$	48'15"	7	0,047	4,7 %
$(48'30", 49']$	48'45"	28	0,189	18,9 %
$(49', 49'30"]$	49'15"	53	0,358	35,8 %
$(49'30", 50']$	49'45"	42	0,283	28,3 %
$(50', 50'30"]$	50'15"	10	0,067	6,7 %
$(50'30", 51']$	50'45"	8	0,054	5,4 %
		$\sum_{i=1}^6 n_i = 148$	$\sum_{i=1}^6 f_i = 1$	$\sum_{i=1}^6 p_i = 100$

### 4.6.3 Indicatori statistici

Pentru o distribuție statistică empirică, consemnată în tabelul frecvențelor, determinăm o serie de **indicatori statistici** în scopul obținerii unor informații cu caracter general privind repartizarea valorilor caracteristicii studiate. Cei mai importanți indicatori statistici sunt: media, mediana și respectiv dispersia distribuției. Media și dispersia indică, fiecare în parte, valoarea "centrală" sau valoarea "de mijloc" a distribuției respective, într-o accepțiune specifică fiecărei noțiuni. Dispersia și respectiv abaterea standard indică gradul de "împrăștiere" a valorilor față de valoarea "centrală" a distribuției. Coeficientul de variație, calculat prin raportarea abaterii standard la medie, oferă posibilitatea stabilirii gradului de omogenitate al eșantionului.

Considerăm o distribuție statistică empirică, asociată unei caracteristici (variabile empirice)  $X$ , care ia valorile  $x_1 < x_2 < \dots < x_k$  cu frecvențele absolute  $n_1, n_2, \dots, n_k$  și respectiv frecvențele relative  $f_1, f_2, \dots, f_k$ .

- **Media**  $\bar{x} = M(X)$  a variabilei  $X$  se calculează prin:

$$\bar{x} = x_1 f_1 + x_2 f_2 + \dots + x_k f_k,$$

sau, utilizând scrierea prescurtată,  $\bar{x} = M(X) = \sum_{i=1}^k x_i f_i$ .

- **Mediana**  $Med = Med(X)$  a variabilei  $X$ , corespunzând unui eșantion de volum  $n$ , se definește astfel: se ordonează crescător valorile caracteristicii tuturor subiecților eșantionului, obținându-se șirul de valori

$$v_1 \leq v_2 \leq \dots \leq v_n.$$

Distingem două situații:

1. dacă  $n = 2p + 1$ , cu  $p$  - număr natural (deci  $n$  este un număr natural impar), atunci  $Med = v_{p+1}$ ;
2. dacă  $n = 2p$ , cu  $p$  - număr natural (deci  $n$  este un număr natural par), atunci  $Med = \frac{v_p + v_{p+1}}{2}$ .

Observăm că din definiția medianei reiese că aceasta este *valoarea care "împarte" eșantionul în două părți de volume egale*

Mediana se mai poate determina și utilizând frecvențele absolute  $n_1, n_2, \dots, n_k$  ale valorilor  $x_1 < x_2 < \dots < x_k$ , după cum urmează:

$$Med = \begin{cases} x_i, & \text{dacă } n_1 + n_2 + \dots + n_{i-1} < \frac{n}{2} < n_1 + n_2 + \dots + n_{i-1} + n_i \\ \frac{x_i + x_{i+1}}{2}, & \text{dacă } \frac{n}{2} = n_1 + n_2 + \dots + n_{i-1} + n_i \end{cases}$$

- **Amplitudinea**  $W = W(X)$  a variabilei  $X$  se definește prin:

$$W = x_{max} - x_{min}$$

Astfel, dacă  $X$  are o distribuție de *tip finit* atunci  $W = x_k - x_1$ , iar dacă  $X$  are o distribuție de *tip continuu* cu valorile în intervalul  $(a, b]$ , atunci  $W(X) = b - a$ .

- **Dispersia**  $\sigma^2 = \sigma^2(X)$  a variabilei  $X$  se definește prin:

$$\sigma^2 = \sum_{i=1}^k (x_k - \bar{x})^2 f_i,$$

unde  $\bar{x} = M(X)$  este media variabilei  $X$ .

- **Abaterea standard**  $\sigma = \sigma(X)$  a variabilei  $X$  se definește prin:

$$\sigma = \sqrt{\sigma^2}$$

- **Coeficientul de variație**  $C_v = C_v(X)$  al variabilei  $X$ , se definește, numai în cazul când toate valorile  $x_i$  ale distribuției  $X$  sunt pozitive, prin:

$$C_v = \frac{\sigma}{\bar{x}}$$

- **Expresia procentuală coeficientului de variație**  $C_{v\%} = C_{v\%}(X)$  este:

$$C_{v\%} = 100 \cdot C_v \%$$

Tabelul următor prezintă interpretarea curentă a **omogenității eșantionului în raport cu variabila  $X$**  după valorile coeficientului de variație exprimat procentual:

Coeficientul de variație $C_{v\%}$	Omogenitatea
0-10%	omogenitate mare
10-20%	omogenitate medie
20-35%	omogenitate mică
peste 35%	eșantion neomogen

Să urmărim calculul indicatorilor statistici definiți anterior pentru distribuțiile din exemplele anterioare. Vom nota cu  $X$  variabila empirică cu distribuția prezentată în Exemplul 1 și respectiv cu  $Y$  variabila empirică cu distribuția descrisă în Exemplul 2.

#### 4.6.4 Calculul indicatorilor statistici ai distribuției variabilei $X$ (Exemplul 1).

**Media:**

$$\bar{x} = 0 \cdot 0,05 + 1 \cdot 0,1 + 2 \cdot 0,2 + 3 \cdot 0,375 + 4 \cdot 0,1 + 5 \cdot 0,15 + 6 \cdot 0,025 = 2,925$$

Rezultă că numărul mediu de reușite este:

$$\bar{x} = M(X) \cong 3$$

**Mediana:**

Avem  $n : 2 = 20$  și  $n_1 + n_2 + n_3 = 14 < 20 < 29 = n_1 + n_2 + n_3 + n_4$ , deci  $Med(X) = x_4$ , sau:

$$Med(X) = 3.$$

**Amplitudinea:**

$$W(X) = 6 - 0 = 6$$

**Dispersia:**

$\sigma^2(X) = (0 - 2,925)^2 \cdot 0,05 + (1 - 2,925)^2 \cdot 0,1 + (2 - 2,925)^2 \cdot 0,2 + (3 - 2,925)^2 \cdot 0,375 + (4 - 2,925)^2 \cdot 0,1 + (5 - 2,925)^2 \cdot 0,15 + (6 - 2,925)^2 \cdot 0,025 = 1,969 \dots$  Dispersia valorilor (abaterea medie pătratică) este deci:

$$\sigma^2(X) \cong 1,97$$

**Abaterea standard:**

$$\sigma(X) = \sqrt{1,969} \cong 1,403$$

**Coeficientul de variație:**

$$C_v(X) = \frac{1,403}{2,925} \cong 0,4797$$

**Expresia procentuală a coeficientul de variație:**

$$C_{v\%}(X) \cong 48\%$$

Interpretare: *eșantion neomogen*.

#### 4.6.5 Calculul indicatorilor statistici ai distribuției variabilei $Y$ (Exemplul 2).

**Media**

$$\bar{x} = 48,25 \cdot 0,047 + 48,75 \cdot 0,189 + 49,25 \cdot 0,358 + 49,75 \cdot 0,283 + 50,25 \cdot 0,067 + 50,75 \cdot 0,054 = 49,29 \dots \text{ (minute)}$$

Rezultă că timpul mediu înregistrat al probei este:

$$M(Y) = \bar{x} \cong 49'18''$$

**Mediana:**

Avem:  $n : 2 = 74$  și  $n_1 + n_2 = 35 < 74 < 88 = n_1 + n_2 + n_3$ , deci  $Med(Y) = x_3$ , adică:

$$Med(Y) = 49'15''$$



**Amplitudinea:**

$$W(Y) = 51 - 48 = 3 \text{ (minute)}$$

**Dispersia:**

$$\begin{aligned} \sigma^2(Y) &= (48,25 - 49,29)^2 \cdot 0,047 + (48,75 - 49,29)^2 \cdot 0,189 + (49,25 - 49,29)^2 \cdot 0,358 + \\ &+ (49,75 - 49,29)^2 \cdot 0,283 + (50,25 - 49,29)^2 \cdot 0,067 + (50,75 - 49,29)^2 \cdot 0,054 = 0,34325 \dots \\ \sigma^2(Y) &\cong 0,343 \end{aligned}$$

**Abaterea standard:**

$$\sigma(Y) = \sqrt{0,343} \cong 0,586$$

**Coeficientul de variație:**

$$C_v(Y) = \frac{0,586}{49,29} \cong 0,012$$

**Exprimarea procentuală a coeficientului de variație:**

$$C_{v\%}(Y) \cong 1,2 \%$$

Interpretarea: *eșantion foarte omogen.*

#### 4.6.6 Compararea a două distribuții empirice

Să presupunem că pentru un eșantion fixat de volum  $n$  se sondează în paralel două caracteristici (variabile empirice)  $X$  și  $Y$  și se pune problema existenței unei conexiuni între distribuțiile acestora. Pentru obținerea unei concluzii se recurge la calculul unor indici de corelație asociați perechii de variabile  $X$  și  $Y$ .

#### 4.6.7 Corelația și coeficientul de corelație

Fie  $\bar{x} = M(X)$ ,  $\bar{y} = M(Y)$  mediile variabilelor  $X$  și  $Y$ , iar  $\sigma_X$ ,  $\sigma_Y$  abaterea lor standard.

Presupunem că  $X$  ia valorile  $x_1 < x_2 < \dots < x_k$  iar  $Y$  ia valorile  $y_1 < y_2 < \dots < y_l$ . Notăm  $n_{i,j}$  numărul unităților statistice ale eșantionului pentru care caracteristica  $X$  ia valoarea  $x_i$  iar caracteristica  $Y$  ia valoarea  $y_j$ , unde  $i = 1, 2, \dots, k$  și  $j = 1, 2, \dots, l$ . Fie  $f_{i,j} = \frac{n_{i,j}}{n}$  frecvența relativă a perechii de valori  $(x_i, y_j)$ .

**Corelația  $c_{X,Y}$  a variabilelor  $X$  și  $Y$**  se definește prin:

$$c_{X,Y} = M((X - \bar{x})(Y - \bar{y})) = \sum_{\substack{i=\overline{1,k} \\ j=\overline{1,l}}} (x_i - \bar{x})(y_j - \bar{y})f_{i,j}$$

**Coeficientul de corelație  $r = r_{X,Y}$  al variabilelor  $X$  și  $Y$**  al variabilelor  $X$  și  $Y$  se definește prin:

$$r = \frac{c_{X,Y}}{\sigma_X \cdot \sigma_Y}.$$

Pe baza unei inegalități matematice fundamentale (*inegalitatea lui Cauchy*) se demonstrează că, oricare ar fi distribuțiile variabilelor  $X$  și  $Y$ , avem:

$$-1 \leq r \leq 1.$$

Interpretarea valorii coeficientului de corelație  $r$  este următoarea:

1. dacă  $r$  este pozitiv, atunci variabilele  $X$  și  $Y$  sunt *corelate*, adică tendința este ca atunci când variabila  $X$  ia o "valoare mare" și variabila  $Y$  să ia tot o "valoare mare". Variabilele  $X$  și  $Y$  sunt cu atât mai puternic corelate cu cât coeficientul lor de corelație este mai apropiat de valoarea 1.
2. dacă  $r$  este negativ, atunci variabilele  $X$  și  $Y$  sunt *invers corelate*, adică tendința este ca atunci când variabila  $X$  ia o "valoare mare" variabila  $Y$  să ia o "valoare mică".
3. dacă  $r$  este apropiat de valoarea 0, atunci variabilele  $X$  și  $Y$  sunt *independente* sau cu o *dependență slabă*.

#### 4.6.8 Metoda corerației rangurilor

Această metodă, datorată lui Spearman, se utilizează atunci când volumul eșantionului este mic (de regulă  $n < 30$ ). Fiecărui individ  $i \in \{1, 2, \dots, n\}$  al eșantionului  $i$  se asociază o pereche de **ranguri**  $(r_i(X), r_i(Y))$ , cu  $r_i(X), r_i(Y) \in [1, n]$ . Aceste ranguri se determină în urma realizării a câte unui "clasament" crescător al valorilor înregistrate pentru fiecare din caracteristicile (variabilele)  $X$  și  $Y$ . Rangurile  $r_i(X)$  și respectiv  $r_i(Y)$  exprimă "poziția" (eventual intermediară) a individului  $i$  în fiecare din cele două "clasamente" de valori crescătoare.

Notăm  $d_i = r_i(X) - r_i(Y)$ ,  $i = 1, 2, \dots, n$ .

**Coeficientul de corelație al rangurilor**  $\rho = \rho_{X,Y}$  asociat variabilelor  $X$  și  $Y$  se definește prin:

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

Se poate verifica prin calcul că, indiferent de distribuția rangurilor, avem:

$$0 \leq \rho \leq 1$$

Dacă  $\rho$  este apropiat de 1, atunci variabilele  $X$  și  $Y$  sunt *corelate* iar dacă  $\rho$  este apropiat de 0, atunci variabilele  $X$  și  $Y$  sunt *invers corelate*.

## 4.7 Test

1. Definiți media empirică și descrieți proprietățile acestui estimator în cazul eșantioanelor Bernoulli.
2. Determinați estimatorul bayesian al unui eșantion Bernoulli asociat unei distribuții  $Beta(\alpha, \beta)$  a parametrului de estimat  $\theta$ .
3. Se observă două variabile aleatoare Bernoulli independente  $X_1$  și  $X_2$ , de parametru  $\theta \in (0, 1)$ . Să se arate că nu se poate găsi un estimator a fără abatere a lui  $\frac{\theta}{1-\theta}$  care să depindă de  $X_1$  și  $X_2$ .
4. Cu ajutorul unui  $n$ -eșantion Bernoulli de parametru  $\theta$  se caută estimarea dispersiei  $\theta(1 - \theta)$ . Să se arate că estimatorul  $T = \bar{X}(1 - \bar{X})$  nu este fără abatere, dar există un multiplu al său având această proprietate.



# Referințe bibliografice

- [1] G. Ciucu, C. Tudor, *Probabilități și procese stochastice*, Ed. Academiei Române, 1979 (vol 1-2).
- [2] I. Cuculescu, *Teoria probabilităților*, Ed. All, 1998.
- [3] D. Dacunha-Castelle, M. Duflo, *Probabilités et statistique*, Masson, 1994 (vol 1).
- [4] W. Feller, *Introduction to probability theory and its applications*, Wiley, New York, 1968.
- [5] P.G. Hoel, *Introduction to mathematical statistics*, Wiley, 1984.
- [6] M. Iosifescu, Gh. Mihoc, R. Theodorescu, *Teoria probabilităților și statistică matematică*, Ed. Tehnică, 1966.
- [7] O. Onicescu, Gh. Mihoc, C. Ionescu-Tulcea, *Calculul probabilităților și aplicații*, Ed. Academiei Române, 1965.