

LUCRAREA 2

Simplificarea gramaticilor independente de context

Cuprinsul lucrării: Sunt prezentate și exemplificate următoarele 4 modalități de simplificare a gramaticilor independente de context:

- Eliminarea λ -producțiilor
- Eliminarea producțiilor ciclice
- Eliminarea recursivității stânga
- Factorizarea stânga

Unele exemple din acest capitol au fost preluate și adaptate din [3], [7] și [1].

2.1 Eliminarea λ -producțiilor

O gramatică λ -free (lambda-free) este o gramatică independentă de context cu următoarele proprietăți:

1. În nicio producție a gramaticii șirul vid nu apare în partea dreaptă a acesteia
2. Dacă există o astfel de producție, atunci ea este $S \rightarrow \lambda$, unde S este simbolul de start, iar S nu apare în partea dreaptă a niciunei alte producții

Teoremă: Pentru orice gramatică independentă de context G , cu λ neaparținând lui $L(G)$, există o gramatică echivalentă λ -free G' .

Demonstrație:

Primul pas este crearea unei mulțimi V_N care cuprinde toți neterminalii din G care pot fi transformați, direct sau indirect, în șirul vid (λ). Acest lucru se realizează în felul următor:

1. Pentru toate producțiile $A \rightarrow \lambda$, se adaugă A în V_N
2. Se repetă pasul următor până când nu se mai adaugă noi simboluri la mulțimea V_N : Pentru toate producțiile de forma $B \rightarrow A_1 A_2 \dots A_n$, unde A_1, A_2, \dots, A_n sunt deja în mulțimea V_N , se adaugă B la V_N .

Al doilea pas, după formarea mulțimii V_N , este formarea de noi producții, adică crearea noii mulțimi P' a gramaticii echivalente G' . Pentru a realiza acest lucru, se analizează toate producțiile din P de forma:

$$A \rightarrow x_1 x_2 \dots x_m, \quad m \geq 1,$$

unde fiecare $x_i \in V \cup T$. Pentru fiecare astfel de producție din P , se adaugă în P' atât producția respectivă, cât și toate producțiile generate pe baza ei în care sunt înlocuite toate simbolurile neterminale din V_N cu λ , în toate combinațiile posibile. Spre exemplu, dacă x_i și x_j sunt ambele în mulțimea V_N , atunci în P' se va regăsi o producție în care x_i va fi înlocuit cu λ , una în care x_j va fi înlocuit cu λ , și respectiv încă o producție în care atât x_i cât și x_j vor fi înlocuite cu λ . Există o excepție de la această regulă, și anume cazul în care toate simbolurile x_i ale producției se regăsesc în mulțimea V_N , și atunci producția rezultată $A \rightarrow \lambda$ nu va fi adăugată lui P' . Noua gramatică G' astfel obținută este o gramatică λ -free, echivalentă cu G .

Exemplu:

Se dă gramatica G definită de producțiile:

$$\begin{aligned} S &\rightarrow ABC \\ A &\rightarrow BB|\lambda \\ B &\rightarrow CC|a \\ C &\rightarrow AA|b \end{aligned}$$

Se cere să se găsească gramatica λ -free G' echivalentă.

Rezolvare:

Primul pas constă din formarea mulțimii V_N .

1. Se adaugă initial simbolurile neterminale care pot fi transformate direct în λ . $V_N = \{A\}$

2. Pentru producțiile care au în partea dreaptă doar simboluri neterminale deja aflate în V_N , se adaugă la V_N simbolurile neterminale din partea stângă. Se repetă acest pas până când nu se mai adaugă noi simboluri la mulțimea V_N .

(a) $V_N = \{A, C\}$ (pentru producția $C \rightarrow AA$)

(b) $V_N = \{A, C, B\}$ (pentru producția $B \rightarrow CC$)

(c) $V_N = \{A, C, B, S\}$ (pentru producția $S \rightarrow ABC$)

S-a obținut deci mulțimea $V_N = \{S, A, B, C\}$. Pe baza acestei mulțimi, al doilea pas constă din generarea de noi producții după regula expusă anterior. De exemplu, din prima producție a lui P :

$$S \rightarrow ABC$$

Se obțin noile producții:

$$S \rightarrow ABC, S \rightarrow AB, S \rightarrow AC, S \rightarrow BC, S \rightarrow A, S \rightarrow B, S \rightarrow C$$

în final, gramatica G' echivalentă obținută este:

$$\begin{aligned} S &\rightarrow ABC|AB|AC|BC|A|B|C \\ A &\rightarrow BB|B \\ B &\rightarrow CC|C|a \\ C &\rightarrow AA|A|b \end{aligned}$$

2.2 Eliminarea producțiilor ciclice

O gramatică are un ciclu dacă există un simbol neterminal A astfel încât $A \Rightarrow +A$ (A să fie derivabil din el însuși printr-o succesiune de producții). Un astfel de simbol se numește simbol ciclic.

Dacă o gramatică G este o gramatică λ -free, atunci toate ciclurile (dacă există) din G pot fi eliminate fără a afecta limbajul generat $L(G)$ folosind un algoritm specific [13].

Fie o gramatică independentă de context $G = (N, T, S, P)$. Pentru eliminarea ciclurilor din această gramatică, mulțimea producțiilor P va fi înlocuită cu noua mulțime P_c obținută din P prin înlocuirea fiecărei producții $A \rightarrow B$, unde B e un simbol ciclic, cu noi producții de tipul $A \rightarrow \alpha$, astfel încât α nu este o variabilă ciclică și există o producție $C \rightarrow \alpha$ astfel încât $B \Rightarrow^* C$.

Gramatica echivalentă rezultată este $G_c = (N, T, S, P_c)$.

Exemplu:

Fie gramatica definită prin producțiile:

$$\begin{aligned} S &\rightarrow X|Xb|SS \\ X &\rightarrow S|a \end{aligned}$$

Atât S cât și X sunt simboluri ciclice pentru că: $S \Rightarrow +S$ și $X \Rightarrow +X$. Aplicând algoritmul de mai sus, se elimină aparițiile simbolurilor ciclice în partea dreaptă a respectivelor producții, obținându-se gramatica echivalentă definită de noile producții:

$$\begin{aligned} S &\rightarrow a|Xb|SS \\ X &\rightarrow Xb|SS|a \end{aligned}$$

2.3 Eliminarea recursivității stânga

O gramatică recursivă stânga este o gramatică în care se regăsește cel puțin un simbol neterminal A și producții specifice prin care să se ajungă la relația:

$$A \Rightarrow +A\alpha \text{ unde } \alpha \in (N \cup T)^*$$

Cu alte cuvinte, printr-o succesiune de producții, simbolul neterminal A este derivat într-o formă în care același simbol apare primul în partea stângă a șirului rezultat.

Recursivitatea stânga este de două feluri:

1. Directă (imediată sau evidentă), în cazul în care există o producție a gramaticii de forma $A \rightarrow A\alpha$,
2. Indirectă (sau „recursivitate în k pași”) atunci când printr-un șir de producții succesive se poate ajunge pornind de la simbolul neterminal A la forma propozițională $A\alpha$.

În general, recursivitatea stânga directă poate fi îndepărtată relativ simplu, prin introducerea unui nou simbol neterminal și a unor noi producții în gramatica inițială.

Presupunând că avem următoarele producții ale neterminalului A care manifestă recursivitate stângă:

$$A \rightarrow A\alpha_1|A\alpha_2|\dots|A\alpha_n|\beta_1|\beta_2|\dots|\beta_m$$

cu proprietatea că niciun simbol β_i nu începe cu A .

Atunci putem înlocui producțiile lui A cu următoarele producții în care introducem noul simbol neterminal A' :

$$\begin{aligned} A &\rightarrow \beta_1 A' | \beta_2 A' | \dots | \beta_m A' \\ A' &\rightarrow \alpha_1 A' | \alpha_2 A' | \dots | \alpha_n A' | \lambda \end{aligned}$$

Sintetizând, putem afirma că recursivitatea imediată se elimină prin înlocuirea unei producții de forma:

$$A \rightarrow A\alpha | \beta$$

Cu două producții de forma:

$$\begin{aligned} A &\rightarrow \beta A' \\ A' &\rightarrow \alpha A' | \lambda \end{aligned}$$

Exemplu:

Eliminați recursivitatea stângă din gramatica definită prin producțiile:

$$\begin{aligned} E &\rightarrow E + T | T \\ T &\rightarrow T * F | F \\ F &\rightarrow (E) | a \end{aligned}$$

Unde $\{E, T, F\}$ sunt simboluri neterminale iar $\{a, +, *, (,)\}$ sunt simboluri terminale.

Rezolvare:

Parcurgem neterminalii pentru a identifica unde ne confruntăm cu recursivitate stângă. Pentru gramatica dată, neterminalii E și T au producții care prezintă recursivitate stângă imediată. În acest caz, rescriem producțiile neterminalilor respectivi conform raționamentului descris mai sus, introducând două noi simboluri neterminale, E' și, respectiv T' . Astfel, noile producții sunt următoarele:

$$\begin{aligned} E &\rightarrow TE' \\ E' &\rightarrow +TE' | \lambda \\ T &\rightarrow FT' \\ T' &\rightarrow *FT' | \lambda \\ F &\rightarrow (E) | a \end{aligned}$$

Pentru eliminarea recursivității stânga atât directă cât și indirectă există următorul algoritm (denumit Algoritmul lui Paull [10]):

Se aranjează neterminalii gramaticii într-o ordine oarecare A_1, A_2, \dots, A_n .

for $i := 1$ to n do begin

 for $j := 1$ to $i - 1$ do begin

 Se înlocuiește fiecare producție de forma $A_i \rightarrow A_j \beta$ cu producțiile:

```

 $A_i \rightarrow \alpha_1\beta|\alpha_2\beta|\dots|\alpha_k\beta$ 
unde
 $A_j \rightarrow \alpha_1|\alpha_2|\dots|\alpha_k$ 
reprezintă toate producțiile actuale ale lui  $A_j$ 
end {for j}
Se elimină recursivitatea stângă imediată din producțiile lui  $A_i$ 
dacă este cazul
end {for i}
```

Exemplu:

Eliminați recursivitatea stângă din gramatica definită prin producțiile:

$$\begin{aligned} S &\rightarrow Aa|b \\ A &\rightarrow Ac|Sd|\epsilon \end{aligned}$$

Rezolvare:

Vom ordona simbolurile neterminale astfel: S, A ($S = A_1, A = A_2$).

- Când $i = 1$, nu se execută bucla după j și se trece direct la eliminarea recursivității imediate pentru producțiile lui S (nu e cazul),
- Când $i = 2$ și $j = 1$, se înlocuiește producția $A \rightarrow Sd$ cu producțiile $A \rightarrow Ac|Aad|bd|\epsilon$,
- În final, se elimină recursivitatea stângă imediată din producțiile lui A .

Se obține astfel noua gramatică având producțiile:

$$\begin{aligned} S &\rightarrow Aa|b \\ A &\rightarrow bdA'|A' \\ A' &\rightarrow cA'|adA'|\epsilon \end{aligned}$$

2.4 Factorizarea stânga

Factorizarea stânga este o tehnică de transformare a unei gramatici independente de context utilă pentru a obține o gramatică echivalentă ce poate fi utilizată în parsarea de tip top-down.

Ideea de bază în spatele factorizării stânga este ca atunci când nu este evident care din două producții alternative ale aceluiași neterminale A este mai potrivită pentru a continua derivarea, aceste producții pot fi rescrise astfel încât decizia se amână până când se cunosc suficiente caractere de intrare pentru a face alegerea corectă.

Pentru a exemplifica, se consideră următoarele producții:

$$S \rightarrow \text{if } E \text{ then } S \\ | \text{if } E \text{ then } S \text{ else } S$$

La întâlnirea unui atom de intrare „if“, nu se poate lua o decizie imediată cu privire la derivarea următoare a lui S .

În general, dacă $A \rightarrow \alpha\beta_1|\alpha\beta_2$ sunt două producții ale lui A iar șirul de intrare începe cu un șir de caractere nevid derivate din α , nu putem ști dacă să derivăm în continuare în $\alpha\beta_1$ sau $\alpha\beta_2$.

Cu toate acestea, se poate modifica gramatica pentru a îndepărta această problemă. Regula este să se modifice producțiile de forma

$$A \rightarrow \alpha\beta_1|\alpha\beta_2$$

în următoarele producții noi, prin introducerea unui nou simbol neterminal A' :

$$A \rightarrow \alpha A' \\ A' \rightarrow \beta_1|\beta_2$$

Aplicând acest raționament, putem rescrie gramatica pentru instrucțiunea if enunțată mai sus astfel:

$$S \rightarrow \text{if } E \text{ then } S \text{ ElsePart} \\ \text{ElsePart} \rightarrow \text{else } S | \epsilon$$

Exemplu:

Fie gramatica definită de producțiile:

$$S \rightarrow Aa|Ab \\ A \rightarrow aabA|aabaA|aa$$

Se cere să se obțină gramatica echivalentă cu aceasta, factorizată stânga.

Rezolvare:

Din analiza gramaticii se observă faptul că trebuie factorizate stânga atât producțiile simbolului neterminal S cât și A . Primul pas îl reprezintă factorizarea producțiilor lui S , pentru care introducem un nou simbol neterminal S' . Astfel, primele două producții devin:

$$S \rightarrow AS' \\ S' \rightarrow a|b$$

În cazul producțiilor lui A observăm prefixul aa comun, și aplicând raționamentul prin introducerea unui nou simbol neterminal B , acestea devin:

$$\begin{aligned} A &\rightarrow aaB \\ B &\rightarrow bA|baA|\lambda \end{aligned}$$

Se observă însă faptul că primele două producții ale lui B prezintă și ele un prefix comun, și anume b . După factorizarea acestora prin introducerea neterminalului C , obținem:

$$\begin{aligned} B &\rightarrow bC|\lambda \\ C &\rightarrow A|aA \end{aligned}$$

Concluzionând, gramatica echivalentă factorizată stânga este:

$$\begin{aligned} S &\rightarrow AS' \\ S' &\rightarrow a|b \\ A &\rightarrow aaB \\ B &\rightarrow bC|\lambda \\ C &\rightarrow A|aA \end{aligned}$$

2.5 Probleme propuse

1. Pentru gramatica definită de producțiile de mai jos, eliminați toate λ -producțiile. Determinați gramatica echivalentă.

$$\begin{aligned} S &\rightarrow aCbb \\ B &\rightarrow CD \\ C &\rightarrow D|a|\lambda \\ D &\rightarrow B|b|\lambda \end{aligned}$$

2. Pentru gramatica definită de producțiile de mai jos, eliminați toate λ -producțiile. Determinați gramatica echivalentă.

$$\begin{aligned} S &\rightarrow AaB|aaB \\ A &\rightarrow \lambda \\ B &\rightarrow bbA|\lambda \end{aligned}$$

3. Eliminați recursivitatea stângă din gramatică definită de producțiile de mai jos. Determinați gramatica echivalentă.

$$\begin{aligned} S &\rightarrow Aa|Bb \\ A &\rightarrow Sa|a \\ B &\rightarrow Bb|b \end{aligned}$$

4. Eliminați recursivitatea stângă din gramatică definită de producțiile de mai jos. Determinați gramatica echivalentă.

$$\begin{aligned}S &\rightarrow S_1\$ \\S_1 &\rightarrow S_1 + T | T \\T &\rightarrow T * F | F \\F &\rightarrow [S_1] | a\end{aligned}$$

Observație: $\{\$, +, *, [,], a\}$ sunt simboluri terminale.

5. Factorizați stânga gramatica definită de producțiile de mai jos. Determinați gramatica echivalentă.

$$\begin{aligned}S &\rightarrow abA | aa \\A &\rightarrow bb | bS\end{aligned}$$